

基于仅三结构域共现的三元对比学习探究

姚昌铭

2026 年 10 月 9 日

目录

1 问题定义	3
1.1 研究背景	3
1.2 仅三结构域共现的样本定义	3
1.3 目标任务	3
1.4 对比学习的基本设想	4
2 现存方法与整体探究思路	4
2.1 相关方法概览	4
2.2 方法总览图	4
3 代表性论文分析	5
3.1 PITF: 基于两两交互的三元组合打分	5
3.1.1 原始问题与任务设定	5
3.1.2 核心方法与训练方式	5
3.1.3 对三结构域任务的启发	6
3.1.4 双域与三域数据的关系分析	7
3.1.5 无需新增训练的初步检索基线	7
3.2 TIRG: 基于组合查询表示的检索	8
3.2.1 原始问题与任务设定	8
3.2.2 核心方法与训练方式	9
3.2.3 对三结构域任务的启发	10
3.2.4 适用条件与待验证问题	11
3.2.5 构造组合查询的四类方案	11
3.3 Symile: 基于多线性打分的联合对比学习	13
3.3.1 原始问题与任务设定	13

目录	2
3.3.2 两两对比的局限：XOR 示例	14
3.3.3 核心方法与训练方式	15
3.3.4 实验验证概述	18
3.3.5 对三结构域任务的启发与待验证问题	18
3.4 方法比较与阶段性判断	20
4 下一步工作：数据获取与性质分析	21
4.1 获取处理后的双域与三域数据	21
4.2 双域与三域共现关系分析	21
4.3 条件允许时开展无需新增训练的检索	22
4.4 阶段目标	22

1 问题定义

1.1 研究背景

本报告从双结构域共现关系的学习出发，进一步探究三个结构域共同构成一个完整蛋白质时的组合关系。希望利用已有蛋白质中的三结构域共现记录，通过对比学习训练模型，为结构域组合检索与补全提供支持。

DOMINO 包含两个模型：DOMIN 通过对比学习，学习结构域之间的共现关系，并为给定结构域检索可能兼容的伙伴；DOMO 则以选定的结构域组合作为条件，生成完整的蛋白质序列，包括结构域之间的连接区域。

本研究主要针对 DOMIN 进行扩展。原始 DOMIN 使用恰有两个注释结构域的蛋白质构建训练样本，将同一蛋白质中的两个结构域作为正例对。沿用这一设定，本研究拟使用恰有三个注释结构域的蛋白质构建三元共现训练集，并通过对比学习学习三个结构域的组合关系，以支持后续的检索与补全。

1.2 仅三结构域共现的样本定义

当前研究以经过筛选、恰有三个结构域的蛋白质记录作为正例来源。将其中的三个结构域记为

$$(A, B, C).$$

这里的“仅三结构域”指同一蛋白质在选定的注释与处理规则下，恰好包含三个结构域实例；它不要求这三个结构域属于不同家族。

图 1 展示了 DOMINO 原文附录中的数据处理流程。本研究拟参考其中用于构建 DOMIN 数据集的分支，将结构域数量筛选条件由 $N_{\text{domains}} = 2$ 调整为 $N_{\text{domains}} = 3$ ，以获取恰有三个注释结构域的蛋白质作为训练数据。




图 1: DOMINO 原文附录中的数据处理流程。本研究拟参考 DOMIN 数据集构建分支，将结构域数量筛选条件由等于 2 调整为等于 3。

1.3 目标任务

研究主要考虑以下两种任务：

1. **二检索一**：给定两个结构域 (A, B) ，从候选集合中检索能够与其共同组成有效组合的结构域 C 。
2. **一检索二**：给定一个结构域 A ，从候选结构域对集合中检索能够与其共同组成有效组合的 (B, C) 。

1.4 对比学习的基本设想

将实际观察到的三结构域共现记录作为正例，通过替换其中一个或多个结构域构造候选负例。训练目标是提高真实组合相对于候选负例的得分。

需要注意，未在数据中观察到的组合不一定在生物学上不兼容，因此需要检查已知正例碰撞及潜在的伪负例问题。

2 现存方法与整体探究思路

2.1 相关方法概览

当前主要考虑三个可借鉴的方向：当前按图中的建模方式，将三结构域兼容性建模分为两两分解建模与联合关系建模，其中联合关系建模进一步分为 $2+1$ 组合建模和直接三元建模，由此形成三条探究路线：

1. **两两分解建模**：将三结构域组合的得分分解为两两关系得分的加和，以 PITF 式打分作为代表，用于建立较为简单的基线。
2. **$2+1$ 组合建模**：先将两个结构域组合为一个查询表示，再与第三个候选结构域匹配，以 TIRG 作为代表。
3. **直接三元建模**：直接对三个结构域的联合关系进行打分，并通过对比目标学习其组合关系，以 Symile 作为代表。

上述三篇论文分别作为三条路线中较为简单、便于展开讨论的代表，并不涵盖各类方法的全部研究。选择这些工作，是为了使当前探究具有明确的讨论对象与主线。如有需要，后续可沿各条路线进一步深入调研；本稿暂不展开其他相关工作的讨论。

2.2 方法总览图

图 2 展示当前问题与相关方法之间的联系。




图 2: 三结构域组合检索的相关方法与探究思路。

3 代表性论文分析

3.1 PITF：基于两两交互的三元组合打分

3.1.1 原始问题与任务设定

PITF (Pairwise Interaction Tensor Factorization) 研究个性化标签推荐问题，其对应论文为 *Pairwise Interaction Tensor Factorization for Personalized Tag Recommendation*。

历史数据由用户、物品和标签构成的三元记录 (u, i, t) 组成，表示用户 u 曾给物品 i 使用标签 t 。预测时，给定用户与物品 (u, i) ，模型对候选标签打分并生成推荐排序。

该任务仅提供正向标注观测，未观测标签并不等同于明确负反馈。论文在同一用户-物品条件下，构造观测标签优于未观测标签的相对排序约束。

3.1.2 核心方法与训练方式

PITF 使用可训练的潜在向量表示实体，通过两两交互的加和计算三元记录的分数。完整形式包含用户-标签、物品-标签及用户-物品三项交互。由于用户-物品项在固定查询的标签排序中为常数，用于标签排序的打分函数可写为

$$s(u, i, t) = \langle \mathbf{u}_u, \mathbf{t}_t^U \rangle + \langle \mathbf{i}_i, \mathbf{t}_t^I \rangle.$$

其中，同一标签使用两套潜在向量，分别参与用户侧与物品侧的交互。单个候选的打分复杂度为 $O(k)$ ，其中 k 为潜在向量维度。

如图 3 所示，对于用户-物品组合 (u_1, i_3) ，观测标签为 t_1, t_4 ，未观测标签为 t_2, t_3, t_5 。训练希望前一组标签的预测分数高于后一组，但不规定两个观测标签之间，或两个未观测标签之间的相对次序。对于没有任何观测标签的组合，无法构造这样的正负标签比较。




图 3: PITF 中由标注记录构造的条件标签排序约束。上方加号表示观测到的标注事件；下方矩阵的横轴为 t_A ，纵轴为 t_B ，加号和减号分别表示支持与反对 $t_A >_{u,i} t_B$ ，问号表示相对次序未知。

具体而言，固定查询 (u, i) ，对于观测标签 t^+ 和未观测标签 t^- ，训练希望满足

$$s(u, i, t^+) > s(u, i, t^-).$$

这里比较的是两项点积之和，并不要求用户侧与物品侧的点积分别都满足相同的大小关系。

论文采用 Bayesian Personalized Ranking (BPR) 优化这一分数差。忽略正则项，单次比较的损失为

$$\mathcal{L}_{\text{BPR}} = -\log \sigma(s(u, i, t^+) - s(u, i, t^-)),$$

其中 σ 为 sigmoid 函数。该目标推动观测标签获得高于未观测标签的分数。这一排序要求属于基于隐式反馈的学习假设，并不意味着未观测标签已被确认不合适。

3.1.3 对三结构域任务的启发

借鉴 PITF 的两两交互思想，可构造三结构域组合的低阶打分基线：

$$s(A, B, C) = s_{AB}(A, B) + s_{AC}(A, C) + s_{BC}(B, C).$$

其中，各项可采用相应角色表示之间的点积。

对于 $2 \rightarrow 1$ 检索，给定 A, B 后， $s_{AB}(A, B)$ 对所有候选 C 相同，候选排名由 $s_{AC}(A, C) + s_{BC}(B, C)$ 决定。对于 $1 \rightarrow 2$ 检索，候选为结构域对 (B, C) ，因此 $s_{BC}(B, C)$ 随候选变化，不能省略。

从恰有三个注释结构域的蛋白质中提取观测正例 (A, B, C^+) ，可固定 (A, B) ，与负候选 C^- 比较，训练模型使

$$s(A, B, C^+) > s(A, B, C^-).$$

这与标签推荐中的排序要求相对应：观测到的完整组合应获得更高分数，未观测组合则作为候选负例，而非已经确认不兼容的组合。

将原论文的实体 ID 向量替换为结构域编码器与投影层，并采用 batch 内候选和 InfoNCE 训练，属于面向三结构域任务的迁移设计，而非原始 PITF 的直接复现。其中，BPR 与 InfoNCE 是不同的训练目标，需要分别说明。

这一基线用于检验两两关系是否足以支持三域检索。虽然训练样本是三元组合，其打分仍由两两交互分解得到，不包含显式的三元交互项。

3.1.4 双域与三域数据的关系分析

后续拟比较恰有两个与恰有三个注释结构域的蛋白质数据集，分析双域共现与三域共现之间的联系。比较前需要确定一致的结构域匹配单位，例如家族或聚类标识，以及是否保留结构域顺序。

对于观测到的三域组合 (A, B, C) ，拟统计其两两子组合 (A, B) 、 (A, C) 和 (B, C) 是否也出现在双域蛋白质中，并比较相应的共现频次与覆盖情况。需要区分：三域蛋白质内部存在某个两两子组合，不等于该组合也在双域蛋白质中被观测。

进一步考察以下两类情况：

1. 两两子组合均在双域数据中得到支持，但完整三域组合未被观测。
2. 完整三域组合已被观测，但部分两两子组合在双域数据中缺少支持。

这些统计用于分析数据覆盖与共现规律，不能仅凭未观测就判定生物学不兼容。结合检索实验，还希望检查：是否存在两两得分接近，但三域共现情况不同的组合，以及双域信息难以区分的三域候选。

在控制数据覆盖、共现频次和训练测试泄漏等因素后，再检验联合建模能否提供超出两两信息的预测收益。

3.1.5 无需新增训练的初步检索基线

作为初步参照，拟复用已有 DOMIN，构建一个无需针对三结构域任务新增训练的 $2 \rightarrow 1$ 检索方法。

给定结构域 A, B ，分别将二者作为 DOMIN 的查询，在同一个候选库中检索 Top- K ：

$$\mathcal{R}_A = \text{TopK}_C s_D(A, C), \quad \mathcal{R}_B = \text{TopK}_C s_D(B, C).$$

其中， s_D 为已有 DOMIN 的兼容性分数，沿用其查询侧与候选侧表示的余弦打分方式。

随后取两个候选集合的交集：

$$\mathcal{R}_{AB} = \mathcal{R}_A \cap \mathcal{R}_B,$$

并对交集集中的候选计算加和分数：

$$s_{\text{TF}}(C \mid A, B) = s_D(A, C) + s_D(B, C), \quad C \in \mathcal{R}_{AB}.$$

最后按照加和分数降序排列候选。

该方法要求候选同时进入两个查询的 Top- K ，再依据其与 A, B 的两两兼容性分数之和进行排序。它借鉴了两两加和的思想，但不学习新的三域联合关系。这里的 training-free 仅指无需新增三域训练，所复用的 DOMIN 已经过训练。

Top- K 交集会引入候选截断：综合得分较高的候选可能未进入某一侧的 Top- K ，交集也可能为空。因此，实验中需要记录交集大小、真实伙伴进入交集的比例和最终检索质量，并考察 K 对结果的影响。

该基线将与双域、三域数据分析结合，用于评估已有双域信息对三域检索的支持程度。其失败可能来自候选截断、双域数据覆盖不足，或两两打分的表达限制，不能直接归因于三元交互缺失。

3.2 TIRG：基于组合查询表示的检索

3.2.1 原始问题与任务设定

TIRG (Text Image Residual Gating) 研究由参考图像与修改文本共同指定目标图像的检索问题，其对应论文为 *Composing Text and Image for Image Retrieval – An Empirical Odyssey*。

这一任务通常称为组合图像检索 (Composed Image Retrieval, CIR)。给定参考图像 x 与修改文本 t ，模型从图像库中检索满足修改要求的目标图像 y 。参考图像提供原有内容，文本则说明希望改变的属性或场景。




图 4: 组合图像检索的任务示例。查询由参考图像与修改文本共同组成，检索目标是图像库中满足修改要求的图像。

如图 4 所示，对于白天的埃菲尔铁塔图像，用户要求“没有人，并切换为夜晚”，模型需要检索保留铁塔主体、同时符合新场景要求的图像。对于下方的合成场景，用户要求在下方中间位置添加红色圆柱，模型需要检索包含这一变化的目标场景。

因此，模型既不能只依据参考图像寻找相似图像，也不能只依据文本进行检索，而需要结合两个输入确定目标。

一条训练样本可表示为

$$(x, t, y).$$

模型分别编码参考图像、修改文本与目标图像，并构造组合查询：

$$\begin{aligned}\phi_x &= f_{\text{img}}(x), & \phi_t &= f_{\text{text}}(t), & \phi_y &= f_{\text{img}}(y), \\ q_{xt} &= F(\phi_x, \phi_t).\end{aligned}$$

训练希望组合查询 q_{xt} 与真实目标表示 ϕ_y 匹配，并与其他候选图像区分。

3.2.2 核心方法与训练方式

TIRG 的主要设计集中在组合模块 F 。论文使用 CNN 编码图像、LSTM 编码文本，再通过门控与残差两个分支构造查询。




图 5: TIRG 的组合表示与训练流程。参考图像和修改文本经过编码后，通过门控分支与残差分支构造组合查询，再与目标图像表示进行匹配。中间的二维空间为概念示意。

如图 5 所示，门控分支调节参考图像信息的保留程度，残差分支提供与修改要求相关的表示变化。最终组合为

$$q_{xt} = w_g f_{\text{gate}}(\phi_x, \phi_t) + w_r f_{\text{res}}(\phi_x, \phi_t),$$

其中， w_g, w_r 为可学习的分支权重。

为说明计算结构，将全局向量版本简写为

$$g = \sigma(W_{g2}\rho(W_{g1}[\phi_x; \phi_t] + b_{g1}) + b_{g2}),$$

$$f_{\text{gate}}(\phi_x, \phi_t) = g \odot \phi_x,$$

$$f_{\text{res}}(\phi_x, \phi_t) = W_{r2}\rho(W_{r1}[\phi_x; \phi_t] + b_{r1}) + b_{r2}.$$

其中, $[\cdot; \cdot]$ 表示拼接, $\odot$ 表示逐元素乘法, ρ 为非线性激活函数, σ 为 sigmoid 函数。

上述公式用于表达向量版的门控残差结构; 原论文还讨论了卷积特征图上的实现, 其中使用带 batch normalization 的卷积, 并将文本表示广播到图像的空间位置。

门控输出与参考图像表示具有相同形状, 通过逐元素相乘调节其各坐标的贡献。残差分支则直接输出一个表示变化, 不要求经过 sigmoid, 也不要求与参考图像逐元素相乘。

该设计以参考图像表示为基础, 通过门控和残差构造修改后的查询。门控分支与残差分支承担不同作用, 不能将 TIRG 简化为仅使用门控权重融合两个输入。

训练时, 设 batch 包含 B 条样本, 组合查询为 q_i , 真实目标表示为 ϕ_i^+ 。采用整个 batch 的目标作为候选时, 论文中的分类形式为

$$\mathcal{L} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(\kappa(q_i, \phi_i^+))}{\sum_{j=1}^B \exp(\kappa(q_i, \phi_j^+))}.$$

其中, κ 为相似度函数, 论文使用点积或负平方欧氏距离。

这一目标要求真实目标相对于其他候选获得更高分数。它与 batch 内对比检索具有相同的基本形式: 每个组合查询对应一个正目标, 其他样本的目标作为负候选。

论文还讨论了每次仅使用一个负候选的情形。此时, 损失可写为

$$\mathcal{L}_{\text{pair}} = \log[1 + \exp(\kappa(q, \phi^-) - \kappa(q, \phi^+))].$$

这一 soft triplet 形式同样优化正负分数差。虽然它与前述 BPR 损失具有相同的代数形式, 但两篇论文的任务、表示结构和负采样方式不同。

3.2.3 对三结构域任务的启发

TIRG 提供的主要启发是: 将两个已知元素组合为查询表示, 再与第三个候选进行匹配。

设结构域编码器输出为

$$h_A = f(A), \quad h_B = f(B), \quad h_C = f(C).$$

经过投影后, 得到

$$a = P_A(h_A), \quad b = P_B(h_B), \quad c = P_C(h_C),$$

其中, $a, b, c \in \mathbb{R}^d$ 。

对于 $2 \rightarrow 1$ 检索, 由两个已知结构域构造查询:

$$q_{AB} = F(a, b),$$

再与候选结构域 C 打分:

$$s(A, B, C) = \left\langle \frac{q_{AB}}{\|q_{AB}\|_2}, \frac{c}{\|c\|_2} \right\rangle.$$

实际实现中, 归一化分母加入小常数, 以避免零向量造成数值问题。

从恰有三个注释结构域的蛋白质中提取正例 (A_i, B_i, C_i) , 可将其他候选 C_j 与其比较, 训练模型提高真实组合的分数。在每个查询只有一个有效正例的简化情形, 可采用

$$\mathcal{L}_{AB \rightarrow C} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(s(A_i, B_i, C_i)/\tau)}{\sum_{j=1}^B \exp(s(A_i, B_i, C_j)/\tau)},$$

其中, $\tau > 0$ 为温度。

与 PITF 式两两加和相比, 这一方案允许组合模块根据 A, B 的共同输入, 生成一个查询表示。最终能否获得超出两两加和的收益, 仍需在相同数据与评价条件下检验。

对于 $1 \rightarrow 2$ 检索, 也可将候选对 (B, C) 编码为组合表示, 再与已知结构域 A 匹配。但需要针对这一方向进行训练, 并另行确定候选结构域对的构造方式。

3.2.4 适用条件与待验证问题

原始 CIR 任务中的参考图像与修改文本具有不同且不对称的角色。在本研究中, 两个输入都是结构域, B 并不是修改 A 的指令。因此, 迁移的是组合查询的计算结构, 而非原任务的完整语义。

尤其对于 TIRG 式门控残差模块, 以 A 为参考表示是一种结构偏置。它并不保证合适的第三结构域 C 应与 A 接近, 需要通过实验判断这一偏置是否有效。

还需明确 A, B 是否具有顺序或位置区分。若忽略顺序, 应采用共享输入投影及对称化处理; 若保留顺序, 则应明确各补全方向对应的位置与角色。

此外, 向量维度相同不等于已经具有可直接组合的语义。投影层和检索训练需要共同建立适合该任务的表示关系, 不能默认预训练 embedding 的加法或乘法一定有效。

比较不同组合模块时, 应尽量固定编码器、候选侧表示、数据划分、负采样和训练目标, 并保留仅使用 A 、仅使用 B 的基线。这样才能判断模型是否利用了两个输入, 以及收益是否来自组合方式本身。

对于已知多答案和重复候选, 需要过滤正例碰撞或采用多正例目标。未观测到的三域组合仍不能直接视为已验证不兼容。

最后, 原论文的消融实验表明, 门控、残差及组合层位置的作用具有数据集差异。因此, 不能预先认定门控方案优于 MLP, 而应在本任务中分别验证。

3.2.5 构造组合查询的四类方案

以下将加法与逐元素乘法归为基础运算一类, 再分别讨论 MLP、交叉注意力和门控残差组合。四类方案均以构造 q_{AB} 为目标, 但其输入粒度与结构假设有所不同。

第一类: 加法与逐元素乘法。 加法组合为

$$q_{AB}^{\text{add}} = a + b.$$

在未归一化的点积打分下,

$$\langle a + b, c \rangle = \langle a, c \rangle + \langle b, c \rangle.$$

因此, 该方案与前述两两分数加和具有直接联系, 可作为连接 PITF 式基线与组合查询方法的简单参照。

若复用归一化后的 DOMIN 查询侧与候选侧表示, 该点积即为两项余弦分数之和。对固定查询的 $a + b$ 再归一化, 不会改变候选排序。但它不包含 Top- K 交集筛选, 因此与前述交集基线的候选范围不同。

逐元素乘法组合为

$$q_{AB}^{\text{mul}} = a \odot b.$$

在未归一化的点积打分下,

$$\langle a \odot b, c \rangle = \sum_{k=1}^d a_k b_k c_k.$$

该形式包含三元乘积, 与后续 Symile 的多线性打分存在联系。但使用这一公式不等于采用 Symile 的完整训练目标。

这两种组合本身不引入新的参数, 但输入投影层仍可训练。若两个输入使用共享投影, 它们对交换 A, B 保持不变。

第二类: 拼接后使用 MLP。 将两个表示拼接为 $2d$ 维输入, 再映射回 d 维:

$$q_{AB}^{\text{MLP}} = W_2 \rho(W_1[a; b] + b_1) + b_2.$$

设隐藏层维度为 h , 则维度变化为

$$2d \rightarrow h \rightarrow d.$$

MLP 可以学习输入相关的非线性组合, 不要求输出始终保留某个输入的表示。它适合作为检验门控等结构是否必要的基础模型。

拼接通常区分输入顺序。如果任务采用无序组合, 可在共享输入投影的前提下使用

$$q_{AB}^{\text{sym}} = \frac{F(a, b) + F(b, a)}{2}.$$

第三类: 交叉注意力。 交叉注意力更适合使用多个 token 或残基级表示。设

$$H_A \in \mathbb{R}^{L_A \times d}, \quad H_B \in \mathbb{R}^{L_B \times d}.$$

以 A 的残基作为 query, B 的残基作为 key 和 value:

$$Q_A = H_A W_Q, \quad K_B = H_B W_K, \quad V_B = H_B W_V,$$

$$U_A = \text{softmax} \left(\frac{Q_A K_B^\top}{\sqrt{d_k}} + M_B \right) V_B,$$

其中, M_B 用于屏蔽 padding 位置。

经过残差、归一化与前馈层后, 对更新后的残基表示进行池化。也可计算反向的 B 对 A 注意力, 将两个池化结果拼接并投影为 q_{AB} 。

如果 A, B 各只有一个全局向量, 且仅以 B 作为唯一的 key, softmax 权重恒为 1, 该注意力路径无法学习对 B 内部不同部分的选择。因此, 不宜将这种单向量实现直接视为有效的细粒度交叉注意力。

残基级方案使用了额外的细粒度信息, 主要计算量随 $L_A L_B d$ 增长。其收益可能来自输入粒度和组合模块两方面, 应作为单独扩展实验说明。

第四类: TIRG 式门控残差组合。 对于全局向量, 可采用

$$\begin{aligned} g(a, b) &= \sigma(\text{MLP}_g([a; b])), \\ r(a, b) &= \text{MLP}_r([a; b]), \\ q_{AB}^{\text{gate}} &= \alpha g(a, b) \odot a + \beta r(a, b). \end{aligned}$$

其中, $g, r \in \mathbb{R}^d$, α, β 为可学习权重。

这一实现保留 TIRG 的门控残差结构, 分别计算参考表示的门控贡献与额外组合信息。若忽略输入顺序, 可对 $F(a, b)$ 与 $F(b, a)$ 进行对称化。

实验中应比较完整模块、仅门控分支和仅残差分支, 以判断两个分支是否均有必要。门控权重反映模型内部的表示调节, 不应直接解释为生物学相互作用强度。

初步实施顺序。 第一轮建议冻结结构域编码器, 缓存全局表示, 比较加法、乘法、MLP 与门控残差组合。各方案沿用相同的候选侧投影与对比目标, 同时记录检索质量、参数量和计算成本。

在全局向量实验形成结果后, 再考虑残基级交叉注意力, 并检验解冻编码器是否改变比较结论。

这些组合模块均可在候选 C 到来之前计算 q_{AB} , 支持候选表示预计算与向量检索。若让 C 也参与交叉注意力, 则需要对每个三元候选联合计算, 属于另一种计算成本更高的打分接口, 应与本节的组合查询方案区分。

3.3 Symile: 基于多线性打分的联合对比学习

3.3.1 原始问题与任务设定

Symile 研究多个模态之间的联合表征学习, 其对应论文为 *Contrasting with Symile: Simple Model-Agnostic Representation Learning for Unlimited Modalities*。名称来自 SYmmetric MultILinear Embeddings, 即对称多线性嵌入。

以三个模态为例, 一条数据包含共同观测的三元组

$$(a, b, c).$$

三个编码器分别处理各模态, 模型通过对比学习, 区分真实共同观测的组合与重新配对的组合。

传统多模态对比方法可以分别学习 a, b 、 a, c 和 b, c 的两两关系。但分别学习两两配对, 与利用多个条件共同预测一个变量, 并不是同一个问题:

$$a \leftrightarrow b, \quad (a, c) \rightarrow b.$$

Symile 提出的问题是：当预测依赖多个输入的联合条件时，分别学习三组两两关联，是否足以保留完整组合中的信息？

其目标是保留分别编码各模态的简单接口，同时利用联合对比目标学习两两关系之外的依赖，支持多个模态共同检索剩余模态。

3.3.2 两两对比的局限：XOR 示例

考虑两个相互独立的二元变量：

$$a, b \sim \text{Bernoulli}(0.5), \quad c = a \oplus b.$$

其中， $\oplus$ 表示异或：两个输入相同，输出为 0；两个输入不同，输出为 1。

四种组合及其概率为

a	b	c	$p(a, b, c)$
0	0	0	1/4
0	1	1	1/4
1	0	1	1/4
1	1	0	1/4

例如，只知道 $a = 1$ 时，可能出现

$$(a, b, c) = (1, 0, 1) \quad \text{或} \quad (1, 1, 0),$$

因此无法确定 b 。

只知道 $c = 0$ 时，可能出现

$$(a, b, c) = (0, 0, 0) \quad \text{或} \quad (1, 1, 0),$$

同样无法确定 b 。

但同时知道 $a = 1, c = 0$ ，即可确定

$$b = 1.$$

更一般地，

$$b = a \oplus c.$$

两个条件联合起来，提供了任意单个条件都没有的预测信息。

在这一分布中，任意两个变量相互独立：

$$I(a; b) = I(a; c) = I(b; c) = 0.$$

但给定第三个变量后，另外两个变量存在依赖：

$$I(a; b \mid c) > 0.$$

以 2 为对数底时，

$$I(a; b \mid c) = 1 \text{ bit}.$$




图 6: 两两信息与联合信息的概念比较。三角形边上的互信息表示两两依赖，内部的条件互信息表示给定其他变量后的依赖。该图为信息关系示意，并非向量空间或距离关系。

因此，两两独立不等于联合独立。三个变量之间可以存在完全无法由两两边缘分布识别的联合关系。

如图 6 所示，两两 CLIP 目标分别处理边上的互信息。在 XOR 示例中，这些互信息均为零，因而没有能够识别异或规则的两两统计信号。

这一例子说明两两目标存在信息层面的局限，但不意味着所有使用两两损失的复杂模型在任何数据上都无法利用联合信息。实际表现还取决于输入、模型结构和训练方式。对于三结构域数据，是否存在类似的联合依赖，仍需要通过统计与实验验证。

3.3.3 核心方法与训练方式

总相关性作为学习目标。 Symile 以总相关性（Total Correlation, TC）作为理论目标：

$$TC(a, b, c) = D_{KL}(p(a, b, c) \parallel p(a)p(b)p(c)).$$

其中， $p(a, b, c)$ 为真实联合分布， $p(a)p(b)p(c)$ 为将三个变量独立抽取后形成的组合分布。总相关性衡量两者的差异，为零时表示三个变量联合独立。

对于 XOR 示例，真实分布只包含四种组合，而独立组合分布包含八种等概率组合。尽管两两互信息均为零，总相关性仍为

$$TC(a, b, c) = 1 \text{ bit}.$$

对三个变量，总相关性还可以分解为

$$\begin{aligned} 3 \text{ TC}(a, b, c) &= 2[I(a; b) + I(a; c) + I(b; c)] \\ &\quad + I(a; b | c) + I(a; c | b) + I(b; c | a). \end{aligned}$$

这说明总相关性同时涉及两两信息与条件依赖，不能简单等同于三组两两互信息之和。

论文由总相关性的多样本下界构造对比目标。实际训练并不需要显式估计全部联合分布或计算 KL 散度，而是通过识别真实组合与独立组合，优化这一理论目标的下界。

多线性内积打分。 设编码后的表示为

$$u = f_a(a), \quad v = f_b(b), \quad w = f_c(c),$$

其中, $u, v, w \in \mathbb{R}^d$ 。论文实现中对各表示进行 L2 归一化。

Symile 使用多线性内积 (Multilinear Inner Product, MIP):

$$s(a, b, c) = \sum_{k=1}^d u_k v_k w_k.$$

该分数可以改写为

$$s(a, b, c) = (u \odot v)^\top w = (u \odot w)^\top v = (v \odot w)^\top u.$$

因此, 给定两个变量时, 可以将对应表示逐元素相乘, 得到检索第三个变量的联合查询。例如, 给定 a, c 检索 b :

$$q_{ac} = u \odot w, \quad s(a, b, c) = q_{ac}^\top v.$$

高分表示模型对该组合给出较高的联合匹配分数, 并不要求 u, v, w 三个向量彼此接近。这一点不同于将两两相似度直接解释为向量靠近的方式。

从理论上, 最优对比打分与联合分布相对于独立组合分布的对数密度比有关:

$$g^*(a, b, c) = \log \frac{p(a, b, c)}{p(a)p(b)p(c)} + \text{常数}.$$

因此, MIP 不应直接解释为未经校准的联合概率或生物学兼容概率。

正负组合与对比损失。 真实共同观测的 (a_i, b_i, c_i) 为正例。以 a_i 为 anchor 时, 保持 a_i 不变, 从 b 与 c 的边缘分布中独立抽取 b^-, c^- , 构造负候选。

假设每个正例对应 J 个负候选, 该方向的损失可写为

$$\ell_{a \rightarrow (b, c)} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(s(a_i, b_i, c_i)/\tau)}{\exp(s(a_i, b_i, c_i)/\tau) + \sum_{j=1}^J \exp(s(a_i, b_{ij}^-, c_{ij}^-)/\tau)}.$$

再分别以 b, c 为 anchor, 得到完整的对称目标:

$$\mathcal{L}_{\text{Symile}} = \frac{1}{3} [\ell_{a \rightarrow (b, c)} + \ell_{b \rightarrow (a, c)} + \ell_{c \rightarrow (a, b)}].$$

这里的 anchor 指训练时保持不变的变量, 不等于下游检索中必须使用的查询形式。训练时对一个变量与另外两个变量的组合进行对比, 学到的三元分数仍可用于两个变量检索第三个变量。

负采样的重要区别在于: 非 anchor 变量需要独立重新组合。若始终将真实的 (b_j, c_j) 作为整体一起替换, 其采样分布更接近

$$p(a)p(b, c),$$

而非

$$p(a)p(b)p(c).$$

因此，二者对应不同的对比问题，不能仅因使用了同一个 MIP 公式就视为相同的 Symile 目标。




图 7: Symile 的联合对比训练与检索流程。左侧展示音频、文本和图像组合的多线性打分，黄色位置表示真实配对的三元组；右侧以音频和文本共同检索候选图像。

训练与检索流程。 如图 7 所示，左侧将不同样本的音频、文本与图像重新组合，形成正例与负候选。右侧固定音频与文本，对每张候选图像计算三元分数，选择得分最高的图像。

这里的 zero-shot 指表征训练完成后，无需为该检索任务再训练一个专门的预测头，并不意味着编码器或投影层没有经过训练。

batch 内高效实现。 图中的立方体展示了所有三元组合，但实际训练不必显式构造 N^3 张量。

以 a 为 anchor，设三个 batch 的表示矩阵为

$$U, V, W \in \mathbb{R}^{N \times d}.$$

分别对 V, W 使用独立随机排列，得到 V_π, W_ρ 。将它们逐元素相乘：

$$P = V_\pi \odot W_\rho,$$

再计算

$$S = UP^T \in \mathbb{R}^{N \times N}.$$

用真实三元组的分数覆盖对角线：

$$S_{ii} = \sum_{k=1}^d U_{ik} V_{ik} W_{ik}.$$

随后以对角线位置作为正确类别，计算温度缩放后的交叉熵。其他两个 anchor 方向采用相同过程。

该实现为每个 anchor 提供 $N - 1$ 个负候选。论文将其称为 $O(N)$ 负采样，指每个 anchor 的负候选数量，并不意味着整个 batch 的计算复杂度为 $O(N)$ 。其分数矩阵仍有 N^2 个元素，主要矩阵乘法计算量为 $O(N^2 d)$ 。

3.3.4 实验验证概述

合成数据实验。 论文将一维 XOR 动机扩展为五维二元数据，通过调节参数，控制预测目标中联合条件信息的强弱。模型给定 a, c ，预测五维变量 b ，共有 $2^5 = 32$ 个候选。

在完整 XOR 情形下，Symile 达到完全正确的预测，两两 CLIP 则接近随机水平 $1/32$ 。该实验验证了联合目标在受控条件下学习高阶依赖的能力，需要与前述一维示例的随机水平 $1/2$ 区分。

多语言数据实验。 Symile-M3 包含音频、文本与图像。文本中包含不同语言的多个类别词，音频使用的语言决定应选择其中哪个类别，模型据此检索对应图像。

例如，文本同时出现不同语言的多个词，当音频使用英语时，需要选择文本中的英语类别词，而非根据音频句子的内容寻找图像。这一任务要求同时利用音频与文本，任意一个输入单独都不足以确定目标。

在包含 2、5、10 种语言的版本中，Symile 的准确率分别约为 93.9%、91.9%、88.2%，两两 CLIP 分别约为 47.3%、18.7%、9.4%。论文还考察了训练模态缺失的情形，测试时仍使用完整三元组。

医疗数据实验。 Symile-MIMIC 包含心电图 (ECG)、血液检验和胸部 X 光片 (CXR)。给定 ECG 与血液检验，模型在一张真实胸片和九张负候选胸片中检索对应胸片。

Symile 的平均准确率为 43.5%，两两 CLIP 为 38.7%，随机水平为 10%。该实验表明联合目标在实际高维数据中能够带来检索收益，但该结果属于胸片匹配实验，不能直接解释为临床诊断能力。

3.3.5 对三结构域任务的启发与待验证问题

Symile 原任务中的三个变量来自不同模态。迁移到本研究时，可以将它们替换为三个结构域变量：

$$(A, B, C).$$

即使三个输入属于同一模态，仍可从恰有三个注释结构域的蛋白质中构造联合共现正例，并学习三者的组合关系。

两个结构域检索第三个结构域。 设结构域表示为

$$z_A = f_A(A), \quad z_B = f_B(B), \quad z_C = f_C(C).$$

采用多线性打分：

$$s(A, B, C) = \sum_{k=1}^d z_{A,k} z_{B,k} z_{C,k}.$$

给定 A, B ，可构造联合查询

$$q_{AB} = z_A \odot z_B,$$

并对候选 C 打分：

$$s(A, B, C) = q_{AB}^\top z_C.$$

候选侧表示可以预计算，因此无需对每个三元组重新运行编码器。

这里先分别归一化结构域表示，再计算乘积与点积。若额外将 q_{AB} 归一化，对于固定查询的候选排名通常不变，但会改变分数尺度及训练目标，不能默认与原始 MIP 训练完全等价。

一个结构域检索其余两个结构域。 固定 A ，对候选结构域对 (B, C) 打分：

$$s(B, C | A) = z_A^\top (z_B \odot z_C).$$

该接口不要求另外定义一个复杂的 pair encoder，但候选对数量可能显著大于单结构域候选数量。

因此，需要明确候选对来自已有观测组合、预筛选结果还是更大的组合空间。能够计算候选对分数，不等于已经解决了候选空间的规模问题。

与前述两条路线的区别。 PITF 式基线通过两两分数加和建模：

$$s_{\text{pair}}(A, B, C) = s_{AB}(A, B) + s_{AC}(A, C) + s_{BC}(B, C).$$

TIRG 式方法通过可学习的组合模块构造查询：

$$q_{AB} = F(z_A, z_B), \quad s_{\text{compose}}(A, B, C) = q_{AB}^\top z_C.$$

Symile 则采用三元乘积打分，并通过联合分布与独立组合分布之间的对比学习结构域表示：

$$s_{\text{MIP}}(A, B, C) = (z_A \odot z_B)^\top z_C.$$

从检索接口看，MIP 同样可以改写为逐元素乘法组合查询。因此，这些路线并非完全互斥的形式分类。Symile 的关键不仅是乘法公式，还包括联合信息目标与相应负采样方式。

打分函数与完整训练目标的区分。 若固定 (A, B) ，仅替换 C 并训练检索损失，可以得到采用 MIP 打分的三域检索模型。但这一采样主要对比

$$p(A, B, C) \quad \text{与} \quad p(A, B)p(C),$$

不等于 Symile 对独立组合分布 $p(A)p(B)p(C)$ 的完整对比设定。

因此，后续应区分两类实验：一类固定训练协议，只比较打分结构；另一类进一步比较目标替换与 Symile 式独立负采样。这样才能分析收益来自表示结构，还是来自联合训练目标。

顺序、参数共享与假负例。 同模态结构域可共享主编码器，再根据位置或角色使用共享或独立投影层。需要明确 A, B, C 对应序列位置，还是不区分顺序的三个元素。

MIP 对输入表示的乘积是对称的，但若不同位置采用不同编码器或投影层，交换原始结构域并不一定保持分数不变。同模态任务还需要统一处理排列和重复结构域，避免将同一有效组合的不同排列误当作负例。

独立重新组合也可能产生已知有效三元组，或尚未观测但可能兼容的组合。因此，需要根据明确的实例、家族或聚类口径检查正例碰撞，并记录过滤规则。

待验证的问题。 XOR 说明联合依赖可能无法由两两统计识别，但并不证明三结构域数据必然存在同样的关系。还需结合双域与三域数据分析，检查两两信息能够解释哪些组合，以及哪些候选难以仅凭两两关系区分。

候选频率也会影响对比打分与条件预测之间的关系：MIP 更接近联合密度比打分，并不天然等于条件概率。对于长尾结构域数据，需要明确评价目标是兼容性排序还是条件频率预测，再决定是否分析候选先验的影响。

本研究首先讨论结构域检索与组合补全，不将其直接等同于新的蛋白质序列生成。最终需要检验：在相同数据划分、候选集合与评价条件下，联合建模是否能够提供超出两两关系的三结构域检索收益。

3.4 方法比较与阶段性判断

PITF、TIRG 与 Symile 分别体现了两两交互加和、组合查询表示和联合对比学习的思路。三篇工作所采用的方案，均与其原始数据的性质、监督信号和任务设置密切相关，因此不宜脱离这些条件，直接判断哪种方法更适合三结构域任务。

PITF 面向用户-物品条件下的标签排序，利用观测标注构造相对偏好约束；TIRG 面向参考图像与修改文本共同指定目标的检索，采用具有明确输入角色的门控残差组合；Symile 则关注多个变量中的联合依赖，通过多线性打分与联合对比目标学习表征。这些设计对应不同的问题假设，不能仅依据原论文的结果进行横向排名。

对于本研究，首先需要明确数据与任务：三域共现能否主要由两两关系解释，同一查询是否存在多个有效答案，结构域顺序与重复是否重要，以及候选集合如何构造。这些性质将直接影响打分函数、损失函数、负采样方式和评价协议的选择。归一化、温度、参数共享及其他实现技巧，也应结合这些条件检验，而非直接照搬原论文配置。

因此，当前阶段的重点是梳理三条路线的假设与适用条件，并在获得处理后的数据后，分析双域与三域共现关系及检索任务的实际特征。暂不确定最终方法、共同基线或实验优先级。后续再依据数据分析结果，提出具体方案并设计对照实验，判断不同表示、打分与训练目标分别解决了什么问题。

4 下一步工作：数据获取与性质分析

4.1 获取处理后的双域与三域数据

下一步希望获取已有处理流程产出的结构域数据，重点取得恰有两个与恰有三个注释结构域的蛋白质记录，以及原始蛋白质与结构域之间的对应关系。

两类数据应尽量采用一致的注释、质量筛选与去重规则，以便比较双域共现与三域共现。希望获取的信息包括：

- 蛋白质 ID、数据来源及结构域数量。
- 结构域 ID、序列位置与排列顺序。
- 可用的家族标签或聚类标识。
- 结构域序列、结构或预计算表示。
- 质量筛选、去重及已有数据划分规则。

其中，蛋白质与结构域的对应关系用于还原共现记录，家族或聚类标识用于跨蛋白质比较结构域组合。预计算表示与已有 DOMIN 模型，则用于条件允许时开展初步检索实验。

4.2 双域与三域共现关系分析

首先统计两类数据的基本规模，包括蛋白质数量、结构域数量、唯一组合数量，以及组合频次和重复情况。

随后，在一致的家族或聚类口径下，对于三域组合 (A, B, C) ，检查其两两子组合

$$(A, B), \quad (A, C), \quad (B, C)$$

是否也出现在双域蛋白质中。

需要区分三域蛋白质内部的两两子组合，与双域蛋白质中独立观测到的共现记录。前者的存在，并不意味着后者也已被观测。

初步分析可围绕以下问题展开：

1. 三域组合中，有多少两两子组合能在双域数据中找到对应记录？可按零个、一个、两个或三个子组合得到支持，对三域组合进行分组。
2. 双域共现频次与三域共现频次之间是否存在联系？常见双域组合是否也经常参与三域组合？
3. 是否存在三个两两子组合均已被观测，但完整三域组合未被观测的情况？反过来，已观测三域组合是否可能包含在双域数据中缺少支持的子组合？
4. 同一结构域对 (A, B) 可以对应多少个第三结构域 C ？同一结构域 A 又可以对应多少个结构域对 (B, C) ？

解释这些结果时，还需考虑结构域本身是否出现在双域数据中，以及两类数据的规模、频次和采样差异。缺少共现记录可能来自覆盖不足，不能直接解释为不兼容。

这些统计用于初步判断双域信息对三域组合的支持程度，并寻找值得进一步验证的联合关系。仅凭共现计数，尚不能证明存在不可由两两关系解释的三元依赖。

4.3 条件允许时开展无需新增训练的检索

若能够获取已有 DOMIN 模型及所需输入，拟先开展一个无需新增三域训练的 $2 \rightarrow 1$ 检索实验。

给定 A, B ，分别使用 DOMIN 在同一候选库中检索 Top- K ，取候选集合的交集，再依据两两分数之和排序：

$$\mathcal{R}_{AB} = \text{TopK}_C s_D(A, C) \cap \text{TopK}_C s_D(B, C),$$

$$s_{\text{sum}}(C \mid A, B) = s_D(A, C) + s_D(B, C).$$

该实验用于检查：已有双域模型的兼容性信息，能否直接支持三域伙伴检索。这里的 training-free 指不进行额外的三域训练。

除最终检索结果外，应记录真实伙伴进入候选交集的比例，并考察 K 的影响。若候选规模允许，还可直接在全部候选上进行两两加和排序，以区分交集截断与打分本身的影响。

检索结果可按前述两两共现支持情况分组分析，检查模型在哪些组合上有效，在哪些组合上难以区分候选。同时应核对已有 DOMIN 训练数据与测试数据的重叠，避免将数据泄漏误认为迁移能力。

4.4 阶段目标

当前阶段优先完成数据获取与共现分析，形成双域、三域数据的规模统计、两两子组合覆盖情况及多答案分布。

条件允许时，再开展上述初步检索，将模型表现与数据性质结合分析。根据这些结果明确任务设置，再决定是否需要三域训练、采用何种联合建模方式，以及如何安排后续对照实验。