三结构域数据分析与 Training-free Benchmark 构建

姚昌铭

2026 年 10 月 20 日

目录

1 研究背景与上次遗留问题 **3**

1.1 DOMINO 三结构域扩展的研究目标 3

1.2 上次讨论的核心问题 3

1.3 本周工作内容与完成情况 3

2 问题一：三结构域数据集分析 **3**

2.1 数据来源与筛选标准 3

2.2 三结构域样本的总体分布 6

2.3 CATH 家族组合及共现分布 7

2.4 AB 到 C 的条件共现关系 8

2.5 更多结构域数量的补充分析 11

2.6 数据集分析的主要结论 13

3 问题二：Training-free Benchmark 设计与实现 **13**

3.1 任务定义与整体框架 13

3.2 两种 Training-free 检索方案 14

3.2.1 DOMO-based Generative Fusion 14

3.2.2 Additive Embedding Fusion 15

3.3 实验数据构建与 Pipeline 实现 16

3.4 检索评价：CATH 四级分类与 Hit@K 18

3.5 生成评价：AlphaFold 结构预测 19

3.6 初步实验结果 19

4 阶段性结果与讨论 **22**

4.1 三结构域数据的主要特征 22

4.2 两种融合方法的初步比较 23
4.3 当前实验的局限性与待解决问题 23

5 下一步工作计划 **24**
5.1 Training-free：完善 Benchmark 与结构验证 24
5.2 Training：小参数模型训练与方法探索 24

1 研究背景与上次遗留问题

1.1 DOMINO 三结构域扩展的研究目标

本研究围绕 DOMINO 的多结构域组合任务，探索如何将已有的双结构域共现检索能力扩展到三结构域场景。整体包含两个任务：一是给定一个结构域，逐步检索并构成三结构域组合；二是给定两个固定的结构域，检索能够与二者共同出现的第三个结构域。

本周优先开展第二个任务，即给定结构域 A 和 B，从候选库中检索第三个结构域 C，记为

$$(A, B) \longrightarrow C.$$

现阶段以真实 AFDB 蛋白链上的 TED 预测域共现记录为参考，构建检索与评测流程，为后续比较不同组合方法提供统一基础。

1.2 上次讨论的核心问题

上次讨论主要留下了两个需要落实的问题。

首先，需要从数据本身出发，明确三结构域任务的数据基础，包括不同结构域数量的蛋白链分布、三结构域样本的规模，以及 CATH 标签下的结构域组合分布。这些统计将用于判断可用数据的覆盖范围，并确定后续 benchmark 的查询构造方式。

其次，需要将三结构域扩展的想法落实为可运行、可评测的基线。现阶段优先采用无需额外训练的方案，明确两个输入域如何用于检索第三个域，并建立统一的结果评价方式。由于同一对输入域可能对应多个已观测的第三域，评测需要保留多个参考答案，并分别考察 CATH 不同层级的命中情况。

1.3 本周工作内容与完成情况

本周工作主要分为数据分析与 benchmark 构建两部分。

在数据分析方面，围绕三结构域任务整理了四张统计图，并结合配套表格分析数据规模、分布特征及其对检索任务的影响，具体结果见下一节。

在 benchmark 构建方面，聚焦于 $(A, B) \to C$ 任务，搭建从数据准备、查询构造、候选检索到结果评价的首个端到端 pipeline。目前正在推进该流程的运行与验证，并按 CATH 的 C、A、T、H 四个层级分别统计 Top-K 命中情况。本周的交付重点是完成这一基础流程，并整理已完成实验的结果，为后续方法比较提供起点。

2 问题一：三结构域数据集分析

2.1 数据来源与筛选标准

本节基于 TED 数据集，分析真实 AFDB 蛋白链上的 TED 预测域共现，重点考察有效结构域数量、三结构域组成、CATH 注释覆盖情况，以及家族层面的条件共现关系。AFDB 提供蛋白

质序列对应的预测结构，TED 则提供预测结构域的划分与相关注释。本研究进一步结合 CATH 层级标签，将具体域实例归纳为家族层面的组合与补全关系。这些记录提供了自然蛋白链中的预测域组合参考，但不等同于经过实验验证的结构域兼容性标签。

原始数据与三域主表构建。 本研究使用的数据文件及其内容如表 1 所示。

表 1: `source_data/` 目录下的六个数据文件及其内容。文件路径均相对于该目录；后两项未被当前三域分析与检索 pipeline 直接使用。

原文件名	内容
`ted_214m_per_chain_segmentation.tsv`	链级 TED 分域概览，包括链 ID、链长、High/Medium/Low 域数量、残基区间及 proteome ID。
`TED/ted_365m.domain_summary.cath.globularity.taxid.tsv`	域级注释，包括域 ID、共识类别、边界、长度、片段数、平均 pLDDT、CATH 标签与分配信息、globularity 及分类学信息等。
`TED/cath_labels.tsv`	40,782,345 个候选域的域 ID、SaProt 序列及 CATH 标签，用于输入查找与检索结果注释。
`TED/key_embeddings.index`	与 `cath_labels.tsv` 逐行对应的 DOMIN key 向量 FAISS 索引，用于候选域检索。
`afdb_aa.fasta`	AFDB 蛋白质全长氨基酸序列。
`TED/retrieval_results_top1000.tsv`	既有检索结果，包括查询域、候选域、匹配分数和序列一致性等。

首先从 TED 链级分域表筛选恰好三个有效域的链，再依据链 ID、TED 域标识、consensus 类别和残基边界与域级注释表进行连接，生成三域注释主表 `tridomain_annotation_details.tsv`。该表共包含 23,202,262 条三域链记录，约 9.2 GiB，每行汇总一条链中三个域的边界、共识类别、CATH 注释及连接状态，用于后续注释覆盖统计、家族组合分析和 benchmark 查询筛选。

图 1 的全局域数量统计来源于链级表扫描；图 2 和图 3 则使用三域主表及其派生的家族频率表。实际绘图读取已生成的汇总结果，无需重复扫描原始大表。

生成的三结构域数据集。 基于上述原始数据，本研究依次生成三域链缓存和三域注释主表，其构建过程如表 2 所示。两者均包含 23,202,262 条恰好具有三个 High/Medium 有效域的蛋白链记录。其中，缓存表保留链级分域信息，注释主表进一步连接三个域的 CATH 标签及相关属性，并按沿序列坐标的顺序组织三个域。

三域注释主表约 9.2 GiB，同时保存预期与实际的域共识类别、残基边界、CATH 标签及分配层级和方法、平均 pLDDT、域长度、连续性，以及连接状态 `join_status` 和完整 H 标签数量 `valid_h_count`。该表用于注释覆盖统计、家族组合分析，以及后续检索查询集的筛选；连续性、家族互异及 AB 支持度等额外限制在 benchmark 查询构建阶段施加，不作为全部三域主表的筛选条件。

表 2: 三结构域数据集及派生统计的生成过程。3H 表示一条三域链的三个有效域均具有完整 CATH-H 标签。

阶段	输入与处理	生成结果
三域链筛选	扫描约 26 GiB 的链级 TED 表，保留 $n_{\text{High}} + n_{\text{Medium}} = 3$ 的链。	`tridomain_targets.tsv`：约 3.0 GiB，包含 23,202,262 条链的有效域共识类别与边界，不含 CATH 注释。
域级注释连接	将三域缓存与约 120 GiB 的域级表连接，按链 ID 和 TED 域标识定位记录，并核对共识类别与残基边界。	`tridomain_annotation_details.tsv`：约 9.2 GiB，保留全部目标链，补充三个域的注释、属性和连接状态。
家族组合统计	统计完整 H 标签覆盖情况；对 9,128,686 条 3H 链的家族标签排序，保留重复家族。	0H–3H 覆盖统计及 53,381 种无序三元家族组合的频率表。
条件共现构建	将三元组合展开为不同的 $AB \to C$ 视图，链内相同视图去重，跨链累加频数。	143,663 种补全关系、56,546 种 AB 输入对，以及相应支持度和补全分布。
检索查询集构建	从主表筛选三个连续域、3H、家族互异且 AB 支持度 ≥ 100 的链，再查找对应域序列。	1,000-query manifest，记录源链、A/B/C 域 ID、家族标签及模型输入信息。

有效域与三域链定义。 本次统计以链级记录为基本单位，共包含 214,683,829 条记录。将 TED consensus 为 High 或 Medium 的预测域定义为有效结构域，Low 类别不计入有效域数量，即

$$N_{\text{eff}} = N_{\text{High}} + N_{\text{Medium}}.$$

其中，$N_{\text{eff}} = 0$ 的链仍保留在总体分布的分母中。本节所称的“三结构域链”，均指恰好包含三个有效域的链，不要求其全部原始 TED 区域数也恰好为三。

在此口径下，共获得 23,202,262 条三结构域链，占全部链级记录的 10.81%。三域子集的链 ID 唯一，预期的 69,606,786 个有效域均成功完成注释连接。当前未进一步使用域长度、平均 pLDDT 或其他结构质量指标筛选该统计子集；High/Medium 的组成及域的连续性作为描述变量进行统计。后续检索实验所采用的额外筛选条件将在第二部分单独说明。

完整 CATH-H 注释子集。 家族组合分析进一步要求三个域均具有完整 CATH-H 注释。具体条件为：注释层级标记为 H，且标签为四层数字形式 `C.A.T.H`。满足条件的三域链共 9,128,686 条，占三域链的 39.34%。后续家族组合及 $AB \to C$ 条件共现统计均基于这一子集。这里的完整注释表示标签可用于家族统计，不构成额外的实验验证或结构质量保证。

表 3 中的有效域数量类别互斥，0H–3H 类别也相互排斥。由于比例保留两位小数，部分比例之和可能略有舍入误差。全量规模目前按链级表的行数统计，尚未独立完成全量链 ID 去重审计；三域子集则已在提取过程中检查链 ID 唯一性。

表 3: 链级数据规模及三结构域链的 CATH-H 注释覆盖情况。上半部分比例以全部链级记录为分母；下半部分比例以全部三结构域链为分母。0H–3H 表示每条三域链中具有完整 CATH-H 注释的域个数。

类别	链级记录数	比例（%）
全部链级记录	214,683,829	100.00
0 个有效域	11,626,332	5.42
1 个有效域	99,189,315	46.20
2 个有效域	67,455,203	31.42
3 个有效域	23,202,262	10.81
≥ 4 个有效域	13,210,717	6.15
三域链：0H	3,638,034	15.68
三域链：1H	4,311,323	18.58
三域链：2H	6,124,219	26.39
三域链：3H	9,128,686	39.34

2.2 三结构域样本的总体分布

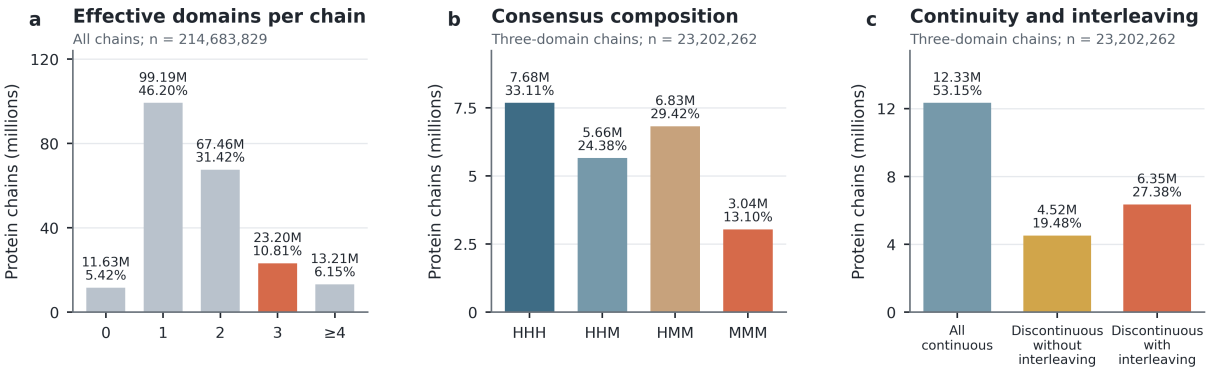


图 1: TED 蛋白质链的有效结构域数量分布及三结构域样本特征。(a) 每条链的有效结构域数量，分母为全部链级记录；(b) 三结构域链的 TED consensus 组成，H 和 M 分别表示 High 和 Medium；(c) 三结构域链沿序列坐标的连续性与交错分布。(b–c) 的分母均为 23,202,262 条三结构域链。

如图 1(a) 所示，单域和双域链分别占全部链级记录的 46.20% 和 31.42%，合计占 77.62%。三域链占 10.81%，具有四个及以上有效域的链占 6.15%。因此，三域链的数量明显少于单域和双域链，但仍具有超过两千万条的样本规模，能够支持进一步的组成分析和检索任务构建。

图 1(b) 展示了三域链的 consensus 组成。HHH、HHM、HMM 和 MMM 分别包含 7,682,302、5,655,891、6,825,580 和 3,038,489 条链，对应比例为 33.11%、24.38%、29.42% 和 13.10%。这里仅统计 High/Medium 的数量组成，不区分其沿序列的排列顺序。HHH 约占三分之一，其余

样本均包含至少一个 Medium 域。因此，当前三域数据是包含不同 consensus 组成的样本集合；若后续仅保留 HHH 链，将明显改变样本规模与组成。

图 1(c) 进一步考察域的序列连续性。一个域若仅由一个残基区间组成，则记为连续域；若包含多个分离的残基区间，则记为不连续域。在至少包含一个不连续域的链中，若各域从最小起点到最大终点形成的包围区间严格分离，则记为“不连续、无交错”，否则记为“不连续、有交错”。这里的交错描述沿序列坐标的穿插关系，不表示不同域占用了相同残基。

三域均连续的链共 12,331,285 条，占 53.15%；不连续、无交错的链共 4,518,802 条，占 19.48%；不连续、有交错的链共 6,352,175 条，占 27.38%。当前未发现实际残基重叠或坐标解析失败的记录，上述三类覆盖全部三域链。

总体而言，46.85% 的三域链至少包含一个不连续域。这一结果说明，将每个结构域都视为一段连续序列，无法覆盖接近一半的三域样本。后续若为简化首轮 pipeline 而仅选取连续域，需要明确这一筛选对评测适用范围的限制。

2.3 CATH 家族组合及共现分布

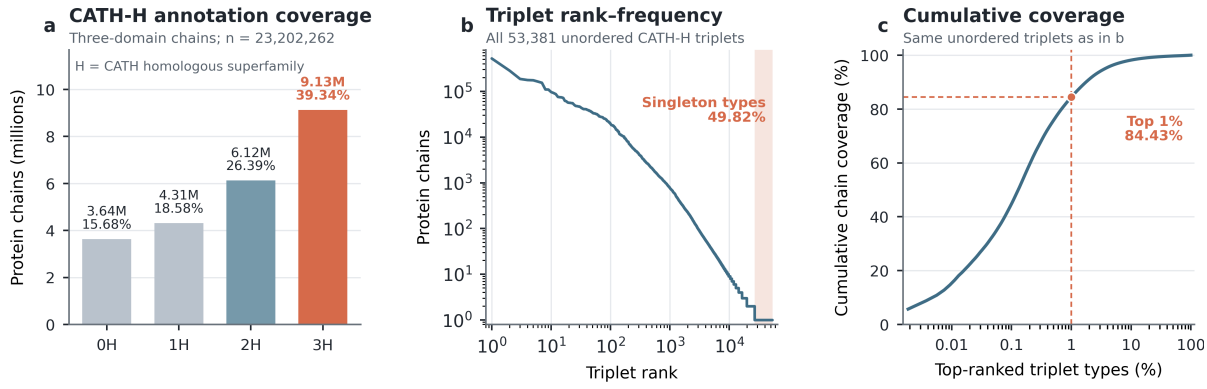


图 2: 三结构域链的 CATH-H 注释覆盖及家族组合分布。(a) 每条三域链中具有完整 CATH-H 注释的域个数；(b) 三域均具有完整注释的子集中，无序三元家族组合的频率分布；(c) 按频率排序的三元组合对该子集中蛋白质链的累计覆盖率。无序组合保留重复家族。

图 2(a) 表明，仅 39.34% 的三域链具有三个完整 CATH-H 标签；其余 60.66% 至少缺少一个完整标签。因此，后续家族组合分析描述的是完整注释子集，不能直接假定其组合分布代表全部三域链。

在 9,128,686 条完整注释链中，共观察到 4,068 个不同 CATH-H 家族。保留沿序列坐标排列的家族顺序时，可获得 64,559 种有序三元架构；将三个标签排序、忽略顺序但保留重复标签后，获得 53,381 种无序三元家族组合。本节后续采用无序组合口径，以聚焦家族共现关系。

图 2(b–c) 显示，不同组合的出现频率高度不均衡。频率最高的前 10、100 和 1,000 种组合，分别覆盖 21.62%、57.95% 和 90.54% 的完整注释链。前 534 种组合约占全部组合类型的 1%，却覆盖 7,707,776 条链，即 84.43%。另一方面，26,596 种组合仅出现一次，占组合类型的 49.82%，

但仅覆盖 0.291% 的链。

这说明，按链抽样时容易集中于少量高频组合，而按组合类型等权统计时则会突出大量低频组合。后续评测需要区分实例频率与组合类型覆盖，避免仅用一个总体平均指标描述两者。

为考察重复家族的影响，将无序组合划分为 AAA、AAB 和 ABC 三类：分别表示三个家族相同、恰有两个家族相同，以及三个家族互异。其中 A、B、C 表示彼此不同的家族，AAB 类也包括排序后呈 ABB 形式的组合。

表 4: 完整 CATH-H 注释子集中不同三元组合类别的组成。链比例以 9,128,686 条完整注释三域链为分母。每链视图数表示链内去重后可产生的不同 $AB \to C$ 补全视图数量。

类别	唯一组合数	链数	链比例（%）	每链视图数
AAA	684	446,737	4.89	1
AAB	15,112	3,292,470	36.07	2
ABC	37,585	5,389,479	59.04	3
合计	53,381	9,128,686	100.00	—

如表 4 所示，AAA 和 AAB 合计覆盖 3,739,207 条链，占 40.96%。重复家族因此并非少量特殊情况。组合规范化需要保留家族的重复次数；若直接将三个标签转换为普通集合，将丢失 AAA 与 AAB 的组成信息。同样，若 benchmark 仅选择 ABC 样本，应明确其暂未覆盖重复家族场景。

2.4 AB 到 C 的条件共现关系

从三元组合到条件补全关系。 上一小节共获得 53,381 种无序 CATH-H 三元家族组合，涉及 4,068 个不同家族。这里需要区分单个家族、三元组合、$AB \to C$ 补全关系及 AB 输入对四个层次。本小节中的 A、B、C 均表示家族标签，并非具体蛋白链上的域实例。

为将三元共现记录转化为补全任务，将每条完整注释三域链拆分为不同的 $AB \to C$ 视图。其中，AB 为允许重复家族的无序对，C 为剩余域的家族标签。同一条链内相同视图仅保留一次，具体规则为

$$
\begin{aligned}
&AAA \longrightarrow (AA) \to A,\\
&AAB \longrightarrow (AA) \to B, \quad (AB) \to A,\\
&ABC \longrightarrow (AB) \to C, \quad (AC) \to B, \quad (BC) \to A.
\end{aligned}
$$

因此，AAB 中两个属于 A 家族的物理域，不会使相同的 $(AB) \to A$ 被重复计数。

按照 AAA、AAB 和 ABC 三类组合的不同展开方式，53,381 种三元组合对应的唯一补全关系数为

$$
\begin{aligned}
N_{\text{relation}} &= 684 + 2 \times 15,112 + 3 \times 37,585\\
&= 143,663.
\end{aligned}
$$

每一条规范化的 (AB, C) 关系均可还原为唯一的无序三元多重集，因此不同三元组合之间不会产生完全相同的 (AB, C) 关系。

进一步仅按输入 AB 去重，得到 56,546 种无序 AB 家族对。不同补全关系可以共享同一个 AB。例如，$\{A, B, C\}$ 与 $\{A, B, D\}$ 分别产生

$$(AB) \to C, \qquad (AB) \to D,$$

这是两种补全关系，但只对应一种 AB 输入对。因此，143,663 不能解释为不同 AB 输入对的数量。

上述转换关系可概括为

$$\underbrace{53,381}_{\text{无序三元组合类型}} \xrightarrow{\text{选择待补全域}} \underbrace{143,663}_{\text{不同补全关系}} \xrightarrow{\text{仅保留输入 AB 并去重}} \underbrace{56,546}_{\text{不同 AB 输入对}} .$$

链频数、支持度与补全度。 记 $n(AB, C)$ 为支持某一补全关系的不同链数，定义 AB 的支持度和经验条件频率为

$$s(AB) = \sum_{C} n(AB, C), \qquad p(C \mid AB) = \frac{n(AB, C)}{s(AB)}.$$

在当前恰好三域、链 ID 唯一且链内视图去重的规则下，每条链对固定 AB 最多贡献一次，所以 $s(AB)$ 等于支持该家族对的不同链数。

与支持度不同，补全度仅统计不同 C 家族的数量：

$$d(AB) = \left|\{C : n(AB, C) > 0\}\right|.$$

因此，$s(AB)$ 描述观测支持量，$d(AB)$ 描述已观测补全的种类数，两者不能混用。所有 AB 的补全度之和等于唯一补全关系数：

$$\sum_{AB} d(AB) = 143,663.$$

另一方面，对所有 AB 的支持度求和时，同一条链可能被计入多个不同视图。由此，9,128,686 条链共产生

$$446,737 + 2 \times 3,292,470 + 3 \times 5,389,479 = 23,200,114$$

个补全视图，即

$$\sum_{AB} s(AB) = 23,200,114.$$

因此，53,381 表示三元组合类型数，143,663 表示不同补全关系数，56,546 表示输入对类型数，23,200,114 则包含各类组合的链出现频率。后者不能解释为不同蛋白质链数。

此外，23,200,114 个补全视图与全部三域链数量 23,202,262 数值接近仅为巧合：前者由 9,128,686 条完整注释链展开得到，后者还包含注释不完整的三域链。

补全分布的集中程度。 为描述不同 C 的频率分布，定义最高频补全占比

$$p_{\max}(AB) = \max_{C} p(C \mid AB),$$

以及基于熵的有效补全多样性

$$D_{\text{eff}}(AB) = \exp\left[-\sum_{C} p(C \mid AB) \ln p(C \mid AB)\right].$$

求和仅涉及已观测到的 C，使用自然对数。若仅有一种 C，则 $D_{\text{eff}} = 1$；若有 m 种 C 且频率相同，则 $D_{\text{eff}} = m$。因此，$d(AB)$ 描述补全种类数，而 $D_{\text{eff}}(AB)$ 还考虑这些补全的频率是否均衡。

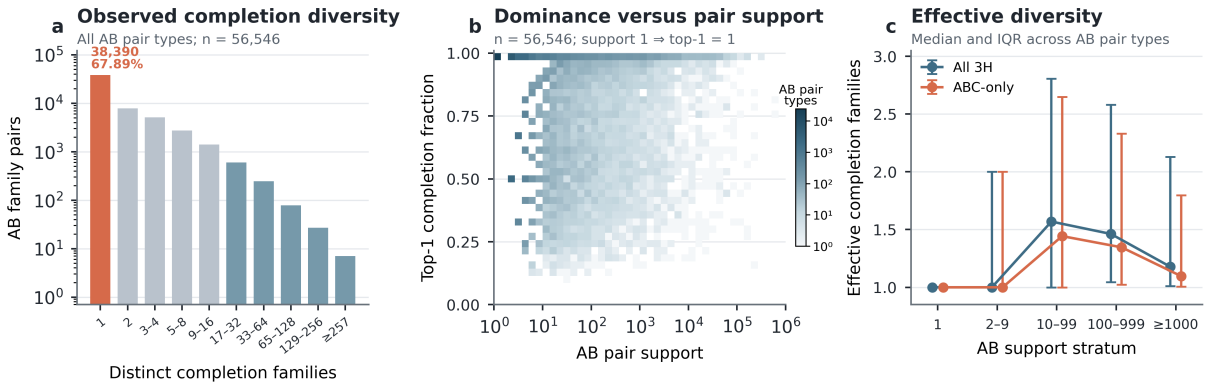


图 3: 三结构域数据中的 $AB \to C$ 条件共现关系。(a) 每种无序 AB 家族对对应的不同 C 家族数量，即补全度 $d(AB)$；(b) AB 支持度与最高频 C 家族占比的关系；(c) 不同支持度分层下的有效补全多样性。对固定 AB，支持度为包含该 AB 的不同完整注释三域链数；跨 AB 累计的支持度为补全视图总数。分层统计以 AB 类型等权计算。

表 5: 三元组合、条件补全关系及输入对的规模摘要。AB 类型比例以 56,546 个唯一 AB 为分母；视图比例以 23,200,114 个补全视图为分母。

指标	数量	比例（%）
无序三元家族组合类型	53,381	—
唯一 (AB, C) 补全关系	143,663	—
唯一无序 AB 家族对	56,546	—
补全视图总数	23,200,114	100.00
仅观察到一种 C 的 AB	38,390	67.89
观察到多种 C 的 AB	18,156	32.11
单 C 的 AB 所覆盖视图	1,646,757	7.10
多 C 的 AB 所覆盖视图	21,553,357	92.90

图 3(a) 和表 5 表明，按 AB 类型计数时，67.89% 的 AB 仅观察到一种 C，32.11% 对应多个 C。全部 AB 的平均补全度为

$$\overline{d} = \frac{143,663}{56,546} \approx 2.54,$$

而补全度中位数为 1。排除 38,390 个单补全 AB 后，多补全 AB 共对应

$$143,663 - 38,390 = 105,273$$

种不同补全关系，其平均补全度为

$$\overline{d}_{\text{multi}} = \frac{105,273}{18,156} \approx 5.80.$$

单个 AB 的最大补全度达到 723。这些结果说明，已观测补全多样性分布高度不均匀：多数 AB 仅关联一个 C，但部分 AB 可关联数百种不同家族，使平均数明显高于中位数。

按补全视图频次计数时，多 C 的 AB 覆盖了 92.90% 的视图。因此，多答案关系虽然不是数量最多的 AB 类型，却覆盖了绝大多数观测视图。

这一现象还与支持度有关。支持度为 1 的 AB 共 24,249 个，占全部 AB 类型的 42.88%。此类 AB 仅有一条支持链，因而只能观察到一种 C；这不能说明其在生物学上只允许一种补全。

随着支持度提高，观察到多个 C 的 AB 比例增加。在支持度为 2–9、10–99、100–999 和至少 1,000 的分层中，多 C 的 AB 比例分别为 42.24%、69.28%、81.86% 和 88.32%。这说明，低支持样本中的单答案现象，至少部分受到观测数量有限的影响。

另一方面，补全种类多并不意味着分布均衡。在支持度至少为 1,000 的 AB 中，不同 C 数量的中位数为 6，但最高频 C 占比的中位数为 0.969，有效补全多样性的中位数仅为 1.178。因此，高支持 AB 通常具有多个已观测补全，同时又常由一个高频 C 主导。

对后续检索评价的启示。 上述结果支持在后续评测中保留多个已观测参考答案，并分别考察支持度与补全度的影响。其中，支持度反映关系的观测充分程度，补全度则决定参考答案集合的大小。在多答案 Hit@K 评价中，较大的参考集合会提供更多潜在命中机会，因此不同补全度查询的总体指标不宜直接解释为相同难度下的检索能力。

后续可按 $d(AB) = 1$、2–4、5–16 和 ≥ 17 分层，分析不同补全多样性下的检索结果。若补全度由全部共现数据计算，应将其称为回顾性分层分析，不据此宣称对未知共现关系的泛化能力。补全度较高本身也不能证明存在高阶交互。

这里的 $p(C \mid AB)$ 是当前数据中的经验频率，不应直接解释为结构域组合的生物学兼容概率；未观测到的 C 也不能直接视为明确不兼容的负例。

2.5 更多结构域数量的补充分析

作为三域分析的补充，图 4 展示了具有 4–20 个有效域的链数量。具有四个及以上有效域的链共 13,210,717 条，占全部链级记录的 6.15%。虽然其总体比例低于三域链，但仍具有千万级样本规模，为后续研究更多结构域的组合任务提供了数据基础。

图中采用对数纵轴，以便同时展示不同数量级的类别。需要区分的是，具有更多有效域的链数，并不等于可直接用于完整家族组合分析的链数；后者仍取决于各域的注释覆盖情况及具体筛选条件。此外，不同域数量对应的数据规模不均衡，未来扩展到可变数量输入时，需要分别检查各类样本的覆盖与评测表现。

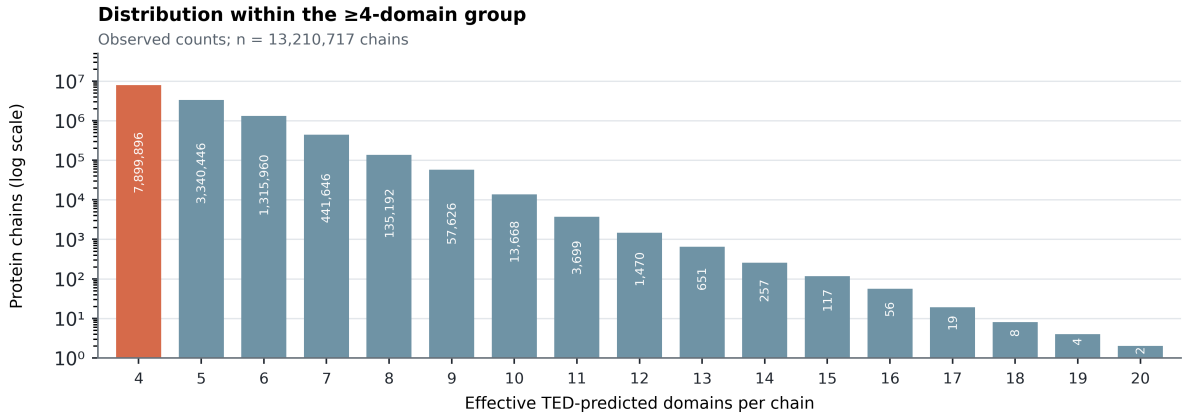


图 4: 具有 4–20 个有效 TED 预测结构域的蛋白质链数量分布。纵轴采用对数刻度。有效域仍定义为 consensus 为 High 或 Medium 的预测域。

本周先聚焦三结构域场景，完成给定两个域检索第三域的基础流程；更多域数量的统计用于说明后续扩展范围，不作为本周已完成的检索任务。

2.6 数据集分析的主要结论

本节分析得到以下结论。

1. **三结构域任务具有充足的数据规模，但完整注释子集的范围需要明确**。全部链级记录中有 23,202,262 条恰好三有效域链，其中 9,128,686 条具有三个完整 CATH-H 标签。家族组合与条件共现结论均基于后者，不能直接推广到全部三域链。

2. **三域样本具有明显的组成差异**。仅 33.11% 的三域链为 HHH，46.85% 至少包含一个不连续域。同时，重复家族组合覆盖完整注释子集的 40.96%。因此，仅选连续域或三个不同家族的样本，都会形成范围更窄的任务子集。

3. **家族组合呈显著的高频集中与长尾分布**。53,381 种无序组合中，前约 1% 覆盖 84.43% 的链，近一半组合却仅出现一次。后续需要区分链实例频率与组合类型覆盖，并关注不同支持度下的表现。

4. **第三域补全具有多答案和频率不均衡特征**。32.11% 的 AB 类型对应多个已观测 C，但覆盖了 92.90% 的补全视图。高支持 AB 虽普遍观察到多个 C，其分布仍可能由一个高频家族主导。因此，补全种类数、最高频占比与有效多样性需要结合解释。

5. **现有统计为检索评测提供参考，尚不能证明模型的补全能力**。当前结果描述预测域的经验共现关系，不证明未观测组合不兼容，也不构成三体相互作用的证据。下一部分将在此基础上构建 $(A, B) \to C$ 检索 pipeline，明确查询、候选库和参考答案，并报告实际检索结果。

3 问题二：Training-free Benchmark 设计与实现

3.1 任务定义与整体框架

本任务研究给定两个结构域条件下的第三域检索。输入为两个具体结构域实例 A 和 B，通过融合二者的信息构建联合查询向量 q_{AB}，从候选结构域数据库 $\mathcal{D}$ 中检索第三个结构域。输出为按匹配分数排序的 Top-K 候选：

$$\mathcal{R}_K(A, B) = \mathrm{TopK}_{C \in \mathcal{D}}\, s(A, B, C).$$

其中，$s(A, B, C)$ 表示联合查询与候选域的匹配分数。检索结果以 TED/CATH 已观测共现关系为参考进行评价，用于考察系统能否找回参考第三域或相应家族，不直接等同于对生物学兼容性的验证。

本研究比较两种 Training-free 查询构建方案：DOMO 生成式融合和 Embedding 加法融合。前者先在序列层面融合两个域，再编码为查询向量；后者分别编码两个域，直接在表示空间中进行融合。这里的 Training-free 指使用已有模型权重进行推理，不针对三域补全任务额外训练或微调模型。

两种方案使用相同的查询样本、候选数据库和评价口径。候选域采用已有 DOMIN key 表征，联合查询采用与之匹配的 query 表征，通过 FAISS 进行向量检索。候选 C 的打分形式为

$$s(A, B, C) = q_{AB}^{\top} k_C,$$

其中 k_C 为候选域的 key 向量。当查询与候选向量均经过 L2 归一化时，该内积等于余弦相似度。

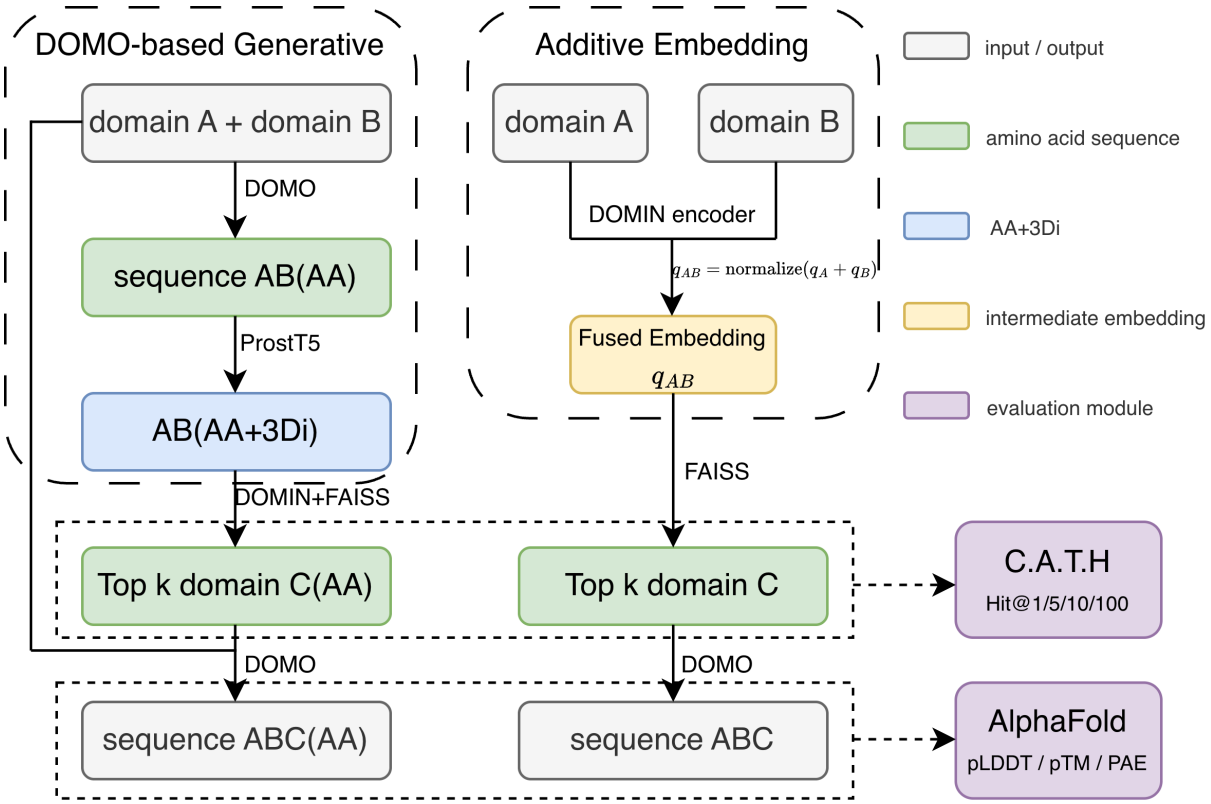


图 5: 两种 Training-free 三结构域补全方案的整体流程。左侧通过 DOMO 生成融合序列，经 ProstT5 和 DOMIN 构建联合查询；右侧通过 DOMIN 表征加法构建联合查询。两种方案均使用 FAISS 检索第三结构域 C。评价分为两个阶段：（1）对于天然已观察到的 ABC 组合，给定 A、B，利用 CATH 层级 Hit@K 评价第三域检索能力；（2）对于数据库中未观察到的 AB 组合，检索 C 后通过 DOMO 生成完整 ABC 序列，并利用 AlphaFold 的 pLDDT、pTM 和 PAE 等指标评估新组合的预测结构合理性。本阶段主要开展第一项检索评价，第二项作为后续研究方向。

3.2 两种 Training-free 检索方案

3.2.1 DOMO-based Generative Fusion

该方案先使用 DOMO，以两个输入域的氨基酸序列 S_A 和 S_B 为条件生成融合序列：

$$\widetilde{S}_{AB} = G_{\text{DOMO}}(S_A, S_B).$$

其中，$\widetilde{S}_{AB}$ 表示模型生成的序列，不预设其为两段输入的直接拼接，也不预设其必然完整保留两个输入域。

由于后续 DOMIN 编码需要 AA+3Di 输入，使用 ProstT5 从生成的氨基酸序列预测 3Di 结构字母序列：

$$\widetilde{Z}_{AB} = P_{\mathrm{ProstT5}}(\widetilde{S}_{AB}).$$

将氨基酸序列与对应的预测 3Di 序列组合，得到 DOMIN 可用的输入

$$\widetilde{X}_{AB} = \mathrm{Pair}\left(\widetilde{S}_{AB}, \widetilde{Z}_{AB}\right),$$

其中 Pair 表示按残基位置配对并转换为模型要求的 AA+3Di 格式。这里的 3Di 来自序列预测，并非对生成序列进行结构预测后提取的结果。

记 f_q 为已有 DOMIN 的查询侧编码映射，包含相应的编码与 query 投影步骤，则生成式融合的联合查询为

$$q_{AB}^{\mathrm{gen}} = \mathrm{Normalize}\left[f_q(\widetilde{X}_{AB})\right].$$

随后使用该向量检索候选域：

$$s_{\mathrm{gen}}(A, B, C) = \left(q_{AB}^{\mathrm{gen}}\right)^{\mathsf{T}} k_C.$$

这一方案考察的是：先生成一条同时以 A、B 为条件的序列，能否使已有 DOMIN 将两个域作为整体用于第三域检索。其效果同时受到 DOMO 生成结果、ProstT5 预测及 DOMIN 编码的影响。因此，检索提升是否成立需要通过实验判断，不能仅由生成式融合的流程推出。

3.2.2 Additive Embedding Fusion

该方案延续上次讨论中由 PITF 启发的两两兼容性分数加和思路：给定两个输入域 A、B，分别计算其与候选域 C 的匹配分数，再将两个分数等权相加。在 DOMIN 的内积打分机制下，这一操作可以转化为先相加查询向量、再进行一次检索，因此本节的 Embedding 加法融合与此前的两两打分方案具有直接的数学联系。

具体而言，复用两个输入域已有的 AA+3Di 表示 X_A 和 X_B，分别通过同一个 DOMIN 查询侧映射获得归一化向量：

$$q_A = \mathrm{Normalize}\left[f_q(X_A)\right], \qquad q_B = \mathrm{Normalize}\left[f_q(X_B)\right].$$

设候选域 C 的已有 key 向量为 k_C，两两兼容性分数加和定义为

$$s_{\mathrm{pair}}(A, B, C) = q_A^{\mathsf{T}} k_C + q_B^{\mathsf{T}} k_C.$$

另一种实现方式是先构建联合查询：

$$q_{AB}^{\mathrm{add}} = \frac{q_A + q_B}{\|q_A + q_B\|_2},$$

其中要求 $q_A + q_B \neq 0$。随后使用该查询向量计算候选分数：

$$s_{\mathrm{add}}(A, B, C) = \left(q_{AB}^{\mathrm{add}}\right)^{\mathsf{T}} k_C.$$

由内积的分配律可得

$$\begin{aligned} s_{\text{add}}(A,B,C) &= \frac{(q_A+q_B)^{\mathsf{T}}k_C}{\|q_A+q_B\|_2} \\ &= \frac{q_A^{\mathsf{T}}k_C+q_B^{\mathsf{T}}k_C}{\|q_A+q_B\|_2} \\ &= \frac{s_{\text{pair}}(A,B,C)}{\|q_A+q_B\|_2}. \end{aligned}$$

对于固定查询 (A,B)，分母为与候选 C 无关的正常数。因此，对任意两个候选 C_1 和 C_2，有

$$s_{\text{add}}(A,B,C_1) > s_{\text{add}}(A,B,C_2) \quad \Longleftrightarrow \quad s_{\text{pair}}(A,B,C_1) > s_{\text{pair}}(A,B,C_2).$$

相等关系也同样保留。故在相同候选集上，两种打分方式具有相同的精确排序：

$$\boxed{\text{rank}_{C\in\mathcal{D}}\, s_{\text{add}}(A,B,C) = \text{rank}_{C\in\mathcal{D}}\, s_{\text{pair}}(A,B,C)}.$$

因此，两两兼容性分数加和与查询 Embedding 加法融合，是同一线性组合打分思想的两种实现形式。不归一化时，向量和的内积与两两分数之和完全相等；归一化后，分数发生统一缩放，但候选排序不变。这里复用的是 PITF 式两两交互加和的思想，并未复现原始 PITF 的参数化方式或训练过程。

实现上，联合查询可直接用于一次 FAISS 检索。若分别检索 A 和 B 后仅合并各自的 Top-K 列表，则不保证得到联合分数的真实 Top-K：某个候选可能在两个单独列表中均未进入前 K，但在分数相加后排名较高。此外，当前 FAISS IVF 索引采用近似检索，上述精确排序等价性不保证不同近似检索流程返回完全相同的候选集合。

加法融合还满足交换不变性：

$$q_{AB}^{\text{add}} = q_{BA}^{\text{add}},$$

因而与本研究优先考察无序家族共现的设定一致。它不需要生成中间序列或额外预测 3Di，可以直接复用已有域表征。但其组合规则本身不额外学习 A、B 与 C 的高阶交互，因此适合作为生成式融合的基础对照。

两种方案的比较旨在检验：相对于此前两两兼容性加和所对应的线性融合基线，先生成融合序列再编码是否能够改善第三域检索。实验除报告相同口径的 Hit@K 外，还应记录运行耗时与处理成功率，以同时比较检索效果和流程开销。

“‘latex

3.3 实验数据构建与 Pipeline 实现

本实验围绕三结构域蛋白中的 $AB \to C$ 补全任务展开：从天然三结构域蛋白中选取两个已知结构域 A、B，利用不同方式构造组合查询表示，并从候选结构域数据库中检索可能与其共同出现的第三个结构域 C。为比较简单表征融合与生成式表征构建的效果，本次实验实现了两条检索 Pipeline，并在统一数据集和候选库上进行评价。

Benchmark 构建 实验以 TED 注释的天然三结构域蛋白为基础，首先选取三个结构域均具有完整四级 CATH 分类标签的蛋白链，再施加以下条件：

- 三个结构域均为连续结构域，避免不连续边界带来的序列处理问题；
- A、B、C 分属不同的 CATH Homology 家族，减少相同家族重复导致的评价歧义；
- 无序结构域家族对 AB 在全部三域共现统计中的支持度不低于 100；
- 对应结构域均可在候选数据库中定位，且 SaProt 输入不包含 `<unk>`。

为控制数据处理成本，采用固定随机种子 20261019 的确定性有界扫描策略。顺序扫描注释数据，收集前 3000 个符合条件的 AB 家族对，每个家族对最多保留 5 条通过稳定哈希选出的代表蛋白链。完成候选库匹配后获得 1815 条完整代表记录，进一步选取 1000 个具有不同无序 AB 家族对的查询样本。

最终 Benchmark 包含 1000 条查询，其中 AB 支持度为 100–999、1000–9999 和不低于 10000 的查询分别为 627、283 和 90 条。

需要说明的是，该 Benchmark 属于固定种子下的确定性子集，并非从全部三结构域蛋白中进行的均匀随机抽样，也不是严格独立的测试集。其主要用途是建立可重复执行的检索与生成评价流程。

两种检索方法 本次实验比较以下两种方法。

（1）Mean(A,B)：基于 DOMIN 表征的直接融合。

分别使用 DOMIN 对两个输入结构域进行编码，获得查询侧表示 $\mathbf{q}_A$ 和 $\mathbf{q}_B$，通过等权平均与 L_2 归一化构造联合查询：

$$\mathbf{q}_{AB} = \mathrm{Normalize}\left(\frac{\mathbf{q}_A + \mathbf{q}_B}{2}\right). \tag{1}$$

利用融合后的查询表示检索候选结构域：

$$s_{\mathrm{Mean}}(A, B, C) = \mathbf{q}_{AB}^{\top}\mathbf{k}_C, \tag{2}$$

其中 $\mathbf{k}_C$ 为 DOMIN 候选侧编码得到的结构域表示。该方案无需额外训练，作为低成本的组合查询 Baseline。

（2）DOMO→ProstT5→DOMIN：基于生成序列的查询构建。

首先将结构域 A、B 的氨基酸序列作为条件输入 DOMO，生成完整蛋白质序列：

$$S_{AB} = \mathrm{DOMO}(A, B). \tag{3}$$

随后通过 ProstT5 预测生成序列的 3Di 结构字母，构造 SaProt 所需的序列–结构联合 Token，并利用 DOMIN 编码生成蛋白，获得查询表示：

$$\mathbf{q}_{AB}^{\mathrm{DOMO}} = f_{\mathrm{DOMIN}}\left(S_{AB}, \mathrm{ProstT5}(S_{AB})\right). \tag{4}$$

最后使用该表示在相同候选库中进行检索。与简单平均相比，该方案试图借助 DOMO 的条件生成能力，将两个独立结构域的信息整合到完整蛋白序列中，再由 DOMIN 提取用于检索的表征。

检索实现 两种方法使用同一个包含 40,782,345 个结构域实例的候选库。检索系统采用 FAISS IndexIVFFlat，Embedding 维度为 1280，索引以 CPU Memory Mapping 方式只读加载。

实验设置 `nprobe=16`，每次首先搜索 256 个候选实例，排除输入结构域 A、B 对应的精确实例后，保留前 100 个候选，统计 Hit@1、Hit@5、Hit@10 和 Hit@100。源链的第三结构域 C 不予排除。

本次实验中，1000 条 DOMO 序列生成和 ProstT5 转换均成功，两种检索方案各完成 1000 次查询，共获得 200,000 条 Top-100 检索记录，未发生影响评价样本数量的 Pipeline 失败。

3.4 检索评价：CATH 四级分类与 Hit@K

为评价检索结果与天然第三结构域的匹配程度，本实验采用 CATH 四级结构分类体系：

- Class（C）：结构域的总体二级结构类别；
- Architecture（C.A）：整体结构架构；
- Topology（C.A.T）：结构拓扑；
- Homology（C.A.T.H）：同源超家族。

对于每个查询 (A, B)，以其天然来源蛋白中的第三结构域 C 为参考。如果 Top-K 候选中至少存在一个结构域，其对应 CATH 分类前缀与参考结构域一致，则记为一次命中：

$$\mathrm{Hit@K}_l = \frac{1}{N}\sum_{i=1}^{N} \mathbb{I}\left[\exists j \le K,\ \mathrm{CATH}_l(\hat{C}_{ij}) = \mathrm{CATH}_l(C_i)\right], \tag{5}$$

其中 $l \in \{C, C.A, C.A.T, C.A.T.H\}$，$N = 1000$，$\hat{C}_{ij}$ 表示第 i 个查询排名第 j 的候选结构域。

这种评价不要求检索到完全相同的结构域实例，而是根据 CATH 分类判断其是否属于相同或相近的结构类别。

此外，本实验还分别考虑两类评价目标：

1. **Strict source-CATH recovery**：要求命中来源蛋白中实际第三结构域 C 对应的 CATH 分类；
2. **Observed completion recovery**：允许命中全量三域共现统计中，与相同 AB 家族对共同出现过的任意 C 家族。

前者用于评价对天然第三结构域的恢复能力；后者用于探索是否能够检索到历史共现关系中的其他合理候选。由于同一个 AB 家族对可能对应多个天然 C，Observed completion 的允许答案集合通常更大，因此两种指标需要分别报告，不能直接等同。

3.5 生成评价：AlphaFold 结构预测

除了检索正确性之外，后续还计划从生成蛋白的三维结构角度评价结构域组合的可实现性。

具体而言，将进一步构造在当前 TED 共现数据中未被观察到的结构域组合，输入 DOMO 生成完整蛋白质氨基酸序列，并利用 AlphaFold 或 ColabFold 进行结构预测。

初步计划使用预测结构的平均 pLDDT 评价局部结构置信度，并结合 pTM、PAE 等指标分析整体结构质量和域间相对排布。对于可确定结构域边界的样本，还可进一步比较各结构域的局部置信度及连接区域的结构合理性。

需要强调的是，较高的整体 pLDDT 并不意味着结构域之间的相互作用或相对构象一定合理，也不能直接证明生成蛋白具有天然功能。因此，后续将区分整体结构置信度与域间组合质量进行分析。

目前，该部分尚未完成结构预测与评价，暂不报告生成三维结构的 pLDDT 或其他结构指标。

3.6 初步实验结果

检索性能比较 图 6 展示了两种方法在 CATH 四级分类及不同 Top-K 设置下的检索表现，并区分严格第三域恢复和历史共现补全两种评价目标。

从严格 source-CATH 评价来看，Mean(A,B) 在所有四个 CATH 层级和四个 Top-K 设置下均优于 DOMO-based retrieval。

以最严格的 Homology（C.A.T.H）层级为例：

表 6: 两种方法在 CATH-H 层级的检索性能比较

方法	Hit@1	Hit@5	Hit@10	Hit@100
Mean(A,B)	29.9%	42.3%	47.3%	59.5%
DOMO-based	19.4%	29.1%	33.9%	45.9%

其中，Mean(A,B) 的 CATH-H Hit@10 达到 47.3%，DOMO-based 方法为 33.9%，前者领先 13.4 个百分点。

在逐查询配对比较中，1000 个查询有 262 个被两种方法同时命中，211 个仅被 Mean(A,B) 命中，77 个仅被 DOMO-based 方法命中，其余 450 个均未命中。通过 10,000 次 Bootstrap 估计，两种方法 Hit@10 差值（DOMO 减去 Mean）的 95% 置信区间为 $[-16.7, -10.2]$ 个百分点。

该结果表明，在当前实验设置下，简单的 DOMIN 表征平均融合已经构成较强的检索 Baseline；通过 DOMO 生成完整序列后再进行编码，并未带来预期的检索性能提升。

一种可能的解释是，DOMO 的生成过程虽然整合了两个输入结构域的序列信息，但生成序

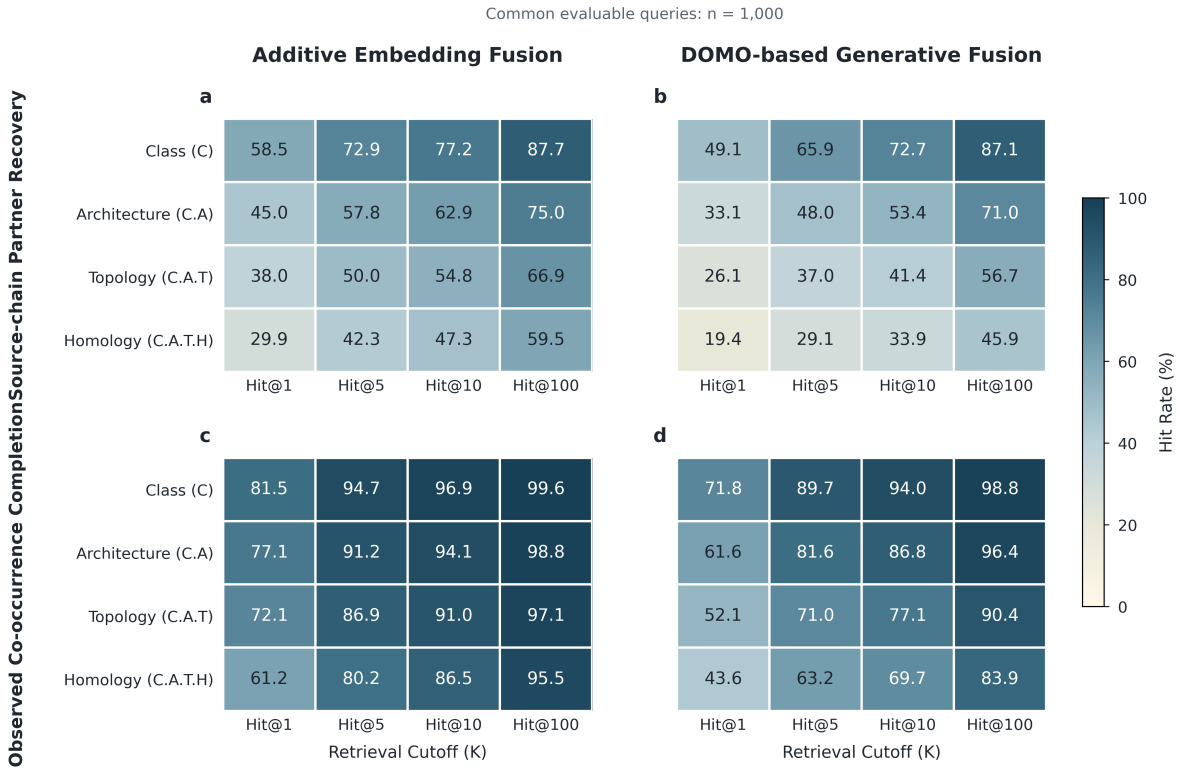


图 6: 两种结构域组合查询方法在三结构域补全 Benchmark 上的检索性能比较。分别展示 Strict source-CATH recovery 与 Observed completion recovery 下，Mean(A,B) 和 DOMO-based retrieval 在 CATH 四级分类及 Hit@1、Hit@5、Hit@10、Hit@100 上的表现。Observed completion 包含源查询对应的天然第三域，因此属于历史共现补全评价，不代表未见组合的泛化能力。

列的整体表征未必更适合恢复原始第三结构域的 CATH 家族。与此同时，完整蛋白中的连接区及额外序列上下文也可能改变 DOMIN 查询表示的分布。目前这些解释仍属于假设，需要进一步实验验证。

不同 AB 支持度下的检索表现 为考察天然共现频率对检索结果的影响，进一步按照 AB 家族对在原始数据中的支持度进行分层。

表 7: 不同 AB 支持度下的严格 CATH-H Hit@10

AB 支持度	查询数	Mean(A,B)	DOMO-based	差值
100–999	627	48.96%	33.33%	-15.63 pp
1000–9999	283	49.12%	38.16%	-10.95 pp
≥ 10000	90	30.00%	24.44%	-5.56 pp

Mean(A,B) 在三个支持度区间均保持领先，但两种方法的命中率并未随 AB 支持度增加而单调提高。特别是在最高支持度区间，两种方法的严格 CATH-H Hit@10 均有所下降。

这说明 AB 共现频率与指定第三域的检索难度之间并不存在简单的单调关系，其表现可能同时受到共现家族分布、候选库组成以及不同家族之间表征相似性的影响。

历史共现补全评价 当评价目标由来源蛋白的单个 C 扩展为同一 AB 家族对历史上曾共同出现的任意 C 时，两种方法的命中率均显著提高。

在包含源查询第三域的 Observed completion 评价下，CATH-H Hit@10 分别达到：

$$\begin{aligned} \mathrm{Hit@10}_{\mathrm{Mean}} &= 86.5\%, \\ \mathrm{Hit@10}_{\mathrm{DOMO}} &= 69.7\%. \end{aligned} \tag{6}$$

对应的 Hit@100 分别为 95.5% 和 83.9%。

这表明，虽然检索结果不一定对应当前来源蛋白中的指定第三域，但仍有相当一部分候选属于历史上与同一 AB 家族对共同出现过的结构域家族。

不过，这一评价使用了更宽泛的允许答案集合，其中包含源查询的天然第三域，且部分允许集合包含与 A 或 B 相同的家族。因此，这些结果仅用于描述已有共现模式的恢复能力，尚不能证明模型能够预测全新的三结构域组合，也不能证明高阶结构域相互作用已经被有效建模。

DOMO 生成序列的结构域恢复情况 本次实验还对 DOMO 输出进行了 Sequence-level Domain Recovery 检查，以确定生成蛋白是否保留输入的两个条件结构域。

在全部 1000 条生成蛋白中，共涉及 2000 个输入结构域。按照局部序列比对的 Identity 阈值 0.90 统计，有 1980 个结构域达到要求，对应的 Per-domain recovery 为 99.0%；其中 983 条生成序列的 A、B 两个结构域均达到该阈值。

进一步采用严格的完整子串匹配，即要求原始结构域氨基酸序列作为连续且完全一致的片段出现在生成序列中，得到：

- 1966/2000 个输入结构域被完整保留，比例为 98.3%；
- 970/1000 条生成序列同时完整保留 A、B，比例为 97.0%；
- 815/1000 条生成序列完整保留 A、B 且维持 $A \to B$ 顺序；
- 155/1000 条生成序列完整保留两个结构域，但排列顺序变为 $B \to A$。

此外，17 条查询存在至少一个结构域的局部序列 Identity 低于 0.90，其中 14 条的生成序列长度达到或接近 1023 aa，提示部分恢复失败可能与生成长度上限有关。

这些结果表明，DOMO 能够以较高保真度保留给定的条件结构域，但生成结果不一定保持天然排列顺序。因此，后续三结构域设计除考察结构域是否存在外，还应进一步区分无序恢复、顺序保持以及整体结构质量。

阶段性结论 本次实验完成了从三结构域样本构建、DOMO 条件生成、ProstT5 结构字母预测，到 DOMIN/FAISS 检索及 CATH 分层评价的完整 Pipeline。

在当前 1000-query Benchmark 中，Mean(A,B) 的检索性能整体优于 DOMO-based 方法，说明简单的表征融合能够为多结构域组合检索提供较强的基线。与此同时，DOMO 表现出较高的输入结构域序列恢复能力，但这种优势并未直接转化为更高的第三域检索命中率。

后续工作将进一步分析不同融合策略在严格三域补全任务中的效果，并通过 AlphaFold 结构预测评估生成蛋白的局部折叠置信度及域间组合质量。“‘ “‘latex

4 阶段性结果与讨论

4.1 三结构域数据的主要特征

通过对 TED 数据集进行系统统计，可以看到三结构域任务具有较大的数据规模，但其内部的家族组成与共现频率存在明显的不均衡性。

首先，虽然三结构域蛋白链数量达到千万级，但只有部分样本具有完整的 CATH-H 注释，同时还存在较多不连续结构域和重复家族组合。因此，当前 Benchmark 优先选择具有完整分类标签、连续边界且三个家族互异的样本，以降低首轮实验的实现和评价复杂度。这一筛选有助于建立可运行的基础流程，但不能直接代表全部三结构域蛋白。

其次，三结构域家族组合呈现明显的长尾分布。少量高频组合覆盖了绝大多数蛋白链，而大量低频组合仅有少数观测记录。对于 $AB \to C$ 任务，同一结构域家族对可能对应多个不同的第三域，但不同候选 C 的出现频率通常并不均衡。

这说明三结构域补全并不是简单的单一答案分类问题。后续评价除了考察是否找回来源蛋白中的第三域，还需要考虑相同 AB 条件下的多个已观测补全结果，并结合家族支持度分析模型表现。同时，未观察到的组合不能直接视为不兼容组合，因此训练数据中的负样本定义也需要谨慎处理。

4.2 两种融合方法的初步比较

本次实验完成了 Mean(A,B) 和 DOMO-based Generative Fusion 两种 Training-free 方法的端到端比较。

实验结果显示，直接对两个 DOMIN 查询 Embedding 进行加法融合，在 CATH 四级分类的各个 Top-K 指标上均优于先通过 DOMO 生成完整序列、再重新编码的方案。其中，在严格 CATH-H Hit@10 指标上，Mean(A,B) 达到 47.3%，DOMO-based 方法为 33.9%。

这一结果说明，简单的线性表征融合已经能够有效利用 DOMIN 原有的结构域兼容性信息，为多结构域检索提供较强的基线。

相比之下，DOMO-based 方法虽然能够以较高的序列保真度保留输入结构域，但并未获得更好的第三域检索表现。可能的原因包括：DOMO 生成的连接区和额外序列上下文改变了原始结构域的表征分布，以及 DOMIN 原本主要面向单个结构域之间的配对检索，其编码器和投影空间未必适合直接处理完整生成蛋白。

此外，Embedding 加法融合具有计算流程简单、无需序列生成及额外结构字母预测等优点，更适合作为后续方法开发的基础对照。不过，该方法本质上仍是两个结构域与候选域的两两兼容性分数加和，并未显式建模三个结构域之间的高阶交互。

因此，当前实验支持优先保留简单融合方案作为 Baseline，同时进一步研究是否能够通过轻量级可训练模块，学习比直接加法更有效的组合查询表示。

4.3 当前实验的局限性与待解决问题

当前实验已经建立完整的 Training-free 检索流程，但仍存在以下限制。

1. **Benchmark 的覆盖范围有限**。目前仅评价 1000 个具有不同无序 AB 家族对的查询，且采用有界扫描和固定筛选条件。实验暂未覆盖低支持度家族对、重复家族组合及不连续结构域，因此还需要扩大样本规模并完善分层评价。

2. **检索评价依赖已观测 CATH 共现关系**。当前 Hit@K 主要衡量对天然来源第三域及历史共现家族的恢复能力。由于多个结构域组合可能具有生物学合理性，未命中已观测参考答案不一定意味着检索结果不兼容。同时，当前测试尚不能证明模型对完全未观察组合的泛化能力。

3. **尚未验证生成蛋白的三维结构质量**。目前的 DOMO 评价主要集中在输入结构域的序列恢复情况，尚未完成 AlphaFold 结构预测。因此，生成序列是否能够形成合理的三结构域构象，以及结构域之间的连接和相对排布是否稳定，仍有待验证。

4. **两种方法均未针对三结构域任务进行训练**。当前直接复用已有 DOMIN 和 DOMO 模型，尚未利用三元共现关系对组合表征进行优化。后续需要比较简单两两加和与显式三元交互建模的差异，判断额外训练是否能够带来稳定的检索性能提升。

5 下一步工作计划

5.1 Training-free：完善 Benchmark 与结构验证

进一步扩大 $AB \to C$ 检索实验规模，完善不同 AB 支持度、CATH 分类层级及 Hit@K 的评价，并增加 A-only、B-only 等 Baseline，比较不同组合查询方法的表现。

同时，选取天然已共现及未观察到的结构域组合，尝试通过 DOMO 生成完整序列，并利用 AlphaFold 进行结构预测，重点评价 pLDDT、pTM 及域间结构合理性。优先完成小规模实验，逐步建立从结构域检索到序列生成、结构验证的完整 Benchmark。

5.2 Training：小参数模型训练与方法探索

首先，尝试自行训练约 35M 参数规模的小模型，熟悉数据处理、模型构建、对比学习训练及模型评价的完整流程。

其次，研究 DOMIN 中 Query/Key（Q/K）的具体实现与作用，探究 Positional Embedding 与原有 Q/K 投影机制的关系，以及如何引入位置信息以支持不同数量结构域的组合检索。

最后，进一步研究 Symile 的多元对比学习方法及其迁移价值，重点分析多线性点积扩展至五个、六个结构域时的分数尺度变化，探索不同结构域数量下检索分数的归一化与对齐方式，为后续可变数量结构域组合模型的设计提供参考。