无数据泄露 Benchmark 构建与 AlphaFold 结构验证方案

姚昌铭

2026 年 11 月 2 日

目录

1 本周工作概述 **3**

1.1 两类评测任务：CATH 共现命中与 AlphaFold 结构评价 3

1.2 上次实验的遗留问题与本周改进重点 3

2 实验一：经过训练来源同源筛查的检索 Benchmark **3**

2.1 任务定义与两种 Training-free 检索方法 4

2.1.1 Additive Embedding Fusion 4

2.1.2 DOMO-based Generative Fusion 4

2.2 经过训练来源同源筛查的 Benchmark 构建 4

2.3 新版 Benchmark 的检索结果与分析 5

2.4 新旧 Benchmark 的构建差异与性能变化潜在原因 7

3 实验二：检索候选生成序列的 AlphaFold 结构评价 **8**

3.1 评价动机：家族命中相近但具体候选不同 8

3.2 实验数据与结构评价流程 8

3.3 整体结构质量与天然结构恢复 9

3.4 未观测 CATH-H 三元组的结构质量分析 9

3.5 代表性结构与案例展示 11

3.5.1 DOMO-based：domo_leakfree_0878 12

3.5.2 DOMO-based：domo_leakfree_0672 12

3.5.3 Mean：mean_leakfree_0126 13

3.5.4 Mean：mean_leakfree_0866 14

3.6 代表性设计蛋白的综合分析 14

4 阶段性总结与下一步计划 **15**

4.1 现有方法的计算开销与多方向补全局限 15
4.2 现有 Benchmark 的任务局限与三方向补全计划 16
4.3 未共现组合数据集的实施计划 16
4.4 新版 Benchmark 的改进与现有结论 17

A 数据构建流程补充材料 **19**

1 本周工作概述

1.1 两类评测任务：CATH 共现命中与 AlphaFold 结构评价

本周围绕两种 Training-free 方法开展评测。首先，通过 CATH 家族命中率比较两种方法检索天然第三域的能力；其次，将各自检回的第三域与相同的 A/B 输入交给 DOMO 生成完整序列，再通过 AlphaFold 评价其结构表现。此外，探讨自然共现数据中未观察到的结构域组合应如何采样，以及后续序列生成与 AlphaFold 结构评测的方案。

1.2 上次实验的遗留问题与本周改进重点

上次实验的数据筛选约束较多，限制了样本的覆盖范围，同时未进行针对训练来源的数据泄露排查。本周放宽部分筛选条件，增加训练来源全长序列的同源筛查，并统一使用 ProstT5 预测查询的结构字母，以改善评测的代表性与比较条件。

2 实验一：经过训练来源同源筛查的检索 Benchmark

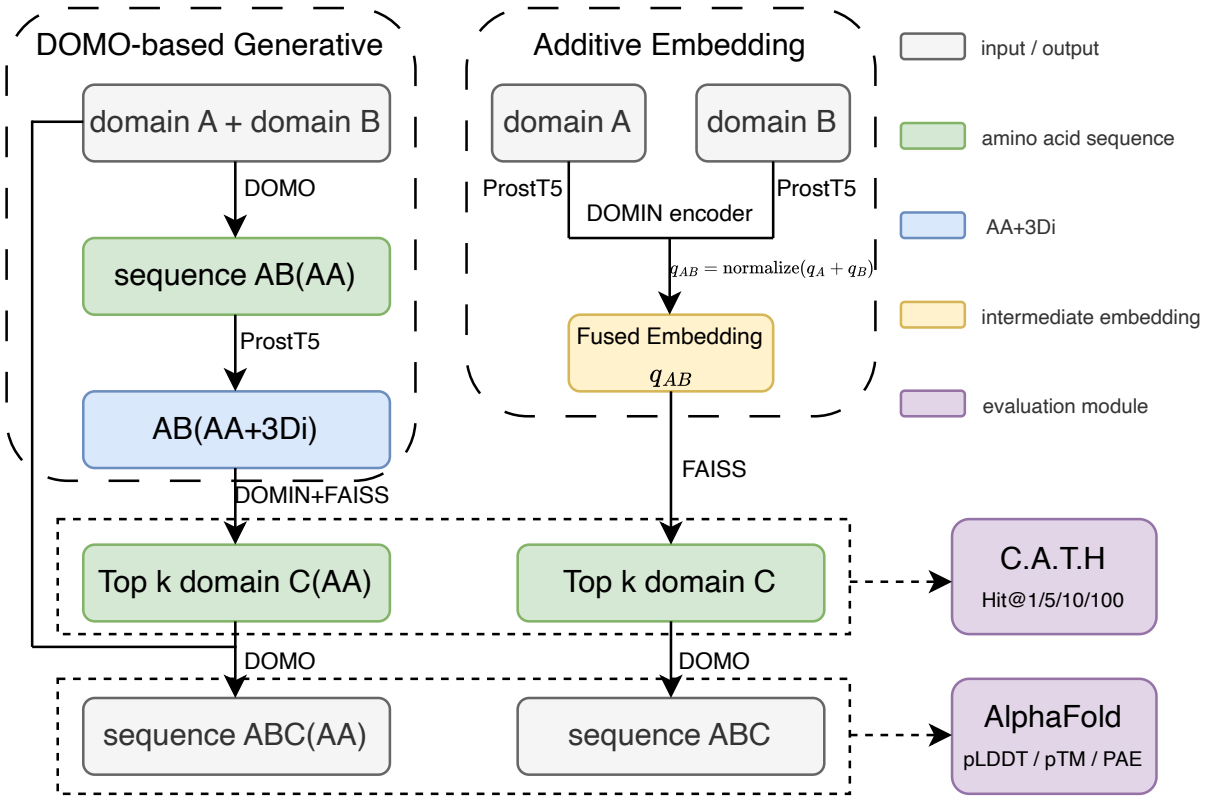


图 1: 两种 Training-free 方法的检索与结构评价流程，与上次相比，这次的加和融合方案同样采用了 Prost T5

2.1 任务定义与两种 Training-free 检索方法

本实验研究给定结构域 A 和 B，检索第三结构域 C 的补全任务。以天然三结构域蛋白中的 A/B 作为输入，从固定候选库中检索 C，并以候选是否属于天然第三域的 CATH 家族作为评价依据。两种方法均复用已有模型，不进行额外训练，整体流程如图 1 所示。

为统一输入信息条件，两种方法均使用 ProstT5 从氨基酸序列预测 3Di，并构建 AA 与 3Di 交织的 SaProt 表示，再通过 DOMIN 查询编码器获得检索向量。区别在于：加和方法分别编码 A/B 后融合向量，DOMO 方法先生成融合序列，再对其进行编码。

2.1.1 Additive Embedding Fusion

该方法分别以天然域 A 和 B 的氨基酸序列为输入，通过 ProstT5 预测各自的 3Di，构建对应的 SaProt 表示 s_A 和 s_B。使用同一 DOMIN 查询编码器 f_Q 分别编码，并进行 L2 归一化：

$$\boldsymbol{q}_A = \frac{f_Q(s_A)}{\|f_Q(s_A)\|_2}, \qquad \boldsymbol{q}_B = \frac{f_Q(s_B)}{\|f_Q(s_B)\|_2}. \tag{1}$$

随后将两个向量相加并再次归一化，得到融合查询：

$$\boldsymbol{q}_{AB}^{\mathrm{Add}} = \frac{\boldsymbol{q}_A + \boldsymbol{q}_B}{\|\boldsymbol{q}_A + \boldsymbol{q}_B\|_2}. \tag{2}$$

使用该向量在 FAISS 候选索引中检索第三域。该方法不生成中间融合序列，以两个输入域的查询表示直接构造组合查询。

2.1.2 DOMO-based Generative Fusion

该方法首先将天然域 A 和 B 的氨基酸序列按顺序输入 DOMO，生成融合序列：

$$x_{AB} = \mathrm{DOMO}(x_A, x_B). \tag{3}$$

由于生成序列没有可直接复用的结构字母，使用 ProstT5 预测整条融合序列的 3Di，构建 SaProt 表示 s_{AB}。随后通过同一 DOMIN 查询编码器编码并归一化：

$$\boldsymbol{q}_{AB}^{\mathrm{DOMO}} = \frac{f_Q(s_{AB})}{\|f_Q(s_{AB})\|_2}. \tag{4}$$

最后使用该向量在相同的 FAISS 候选索引中检索第三域。因此，两种方法的主要区别是组合信息的形成方式：前者在查询向量层面进行加和，后者通过生成融合序列构造组合表示。

两种方法采用相同的候选库与检索参数，并通过 CATH 家族 Hit@K 评价检索结果。后续分别选取各自的 Top-1 候选 C，与相同的天然 A/B 一起输入 DOMO，生成完整三域序列，用于实验二的 AlphaFold 结构评价。

2.2 经过训练来源同源筛查的 Benchmark 构建

LMDB 与 ID 文件的对应以及训练来源全长序列的恢复。 DOMIN 训练 LMDB 包含 60,090,343 条匿名结构域对记录。通过训练 ID 文件 `train_20260215.tsv` 与 TED 双结构域链注释，按照

原始记录顺序重建 `pair_id` 到来源蛋白 `mem_id` 的映射。前 10,000 对结构域的序列验证全部一致。随后从 AFDB FASTA 中恢复 60,090,343 条训练来源蛋白的全长序列，构建 MMseqs2 同源性筛查目标库。

MMseqs2 具体筛选方式以及抽样方式。 首先从 9,128,686 条具有完整 CATH-H 注释的三结构域蛋白中，通过 SHA-256 bottom-k 抽样获得 50,000 条候选序列（seed=20261019）。

使用 MMseqs2 将候选蛋白全长序列（Query）与 DOMIN 训练来源全长序列（Target）进行比对，核心命令如下：

```
mmseqs search QUERY_DB TARGET_DB RESULT_DB TMP_DIR \
    --min-seq-id 0.5 \
    -c 0.8 --cov-mode 1 \
    --seq-id-mode 0 \
    -s 5.7 -e 1e-3 \
    --max-seqs 10000 --threads 14
```

其中，`--min-seq-id 0.5` 要求序列一致性至少为 50%，`-c 0.8 --cov-mode 1` 要求比对覆盖至少 80% 的训练来源蛋白（Target）。采用单侧 Target 覆盖度而非双侧覆盖度，主要考虑到三结构域测试蛋白与双结构域训练来源蛋白可能存在长度差异。即使测试蛋白包含训练蛋白的大部分序列，其额外的第三结构域也可能导致 Query 覆盖度低于 80%。因此，仅限制 Target 覆盖度可以减少此类潜在训练重叠的漏检。

CPU 搜索排除 47,480 条存在符合阈值命中的序列，剩余 2,520 条经 GPU 复查后均无新增命中。最后再次使用 SHA-256 bottom-k 抽样（seed=20261026），选取 1,000 条构建固定 Benchmark。

2.3 新版 Benchmark 的检索结果与分析

测试集组成与结构域序列提取。 从 9,128,686 条具有完整 CATH-H 注释的三结构域蛋白中，经过训练来源同源筛查与两轮抽样，最终获得 1,000 条测试链，包含 405 种不同的 AB 家族对。

其中，595 条链的三个结构域均连续，285 条存在不连续且交错的结构域，120 条存在不连续但不交错的结构域。按照 TED 注释顺序确定 A、B、C，对于不连续结构域，按残基边界顺序提取并拼接其序列。

相较于旧版，新版不再要求结构域连续、三个 CATH-H 家族互异或 AB 家族对唯一，因此覆盖了更加多样的天然结构域组合。

CATH 分层命中率与两种方法的性能比较。 在新版 Benchmark 上，两种 Training-free 方法在 CATH 四级分类下的命中率总体呈现一致趋势：随着检索深度 K 从 1 增大到 100，命中率持续上升；随着评价层级从最宽松的 Class 逐步收紧到最严格的 Family，命中率则逐步下降。总体来看，DOMO-based Generative Fusion 在大多数指标上略优于 Additive Embedding Fusion，尤其在较宽松的分类层级下优势更明显。

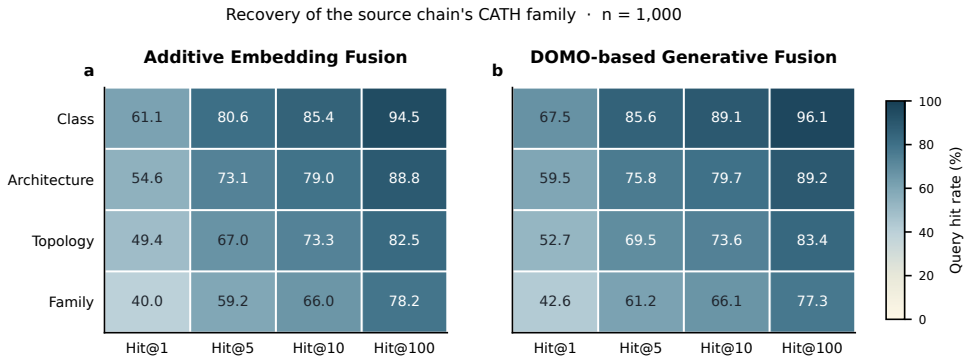


图 2: 两种 Training-free 方法在新 benchmark 上的 CATH 分层检索结果。(a) Additive Embedding Fusion；(b) DOMO-based Generative Fusion。横轴为 Hit@K，纵轴为 CATH 分类层级，颜色深浅表示命中率（%）。

与旧版 Benchmark（图 3）相比，新版测试集上两种方法的表现出现了明显变化。旧版中，Additive Embedding Fusion 在全部 CATH 层级和 Hit@K 指标上均显著优于 DOMO-based Generative Fusion，其中最严格的 Homology 层级 Hit@10 分别为 47.3% 和 33.9%。而在新版 Benchmark 中，两种方法在 Homology 层级的 Hit@10 分别提升至 66.0% 和 66.1%，表现基本持平，DOMO-based 方法甚至在多数其他指标上取得领先。

这一结果说明，两种方法的相对性能对 Benchmark 的构建方式可能较为敏感。考虑到新旧版本在抽样单位、结构域连续性、家族重复情况及 AB 家族分布等方面均存在差异，下一节将进一步分析造成性能变化的潜在原因，重点探究数据分布变化与两种融合策略之间的关系。

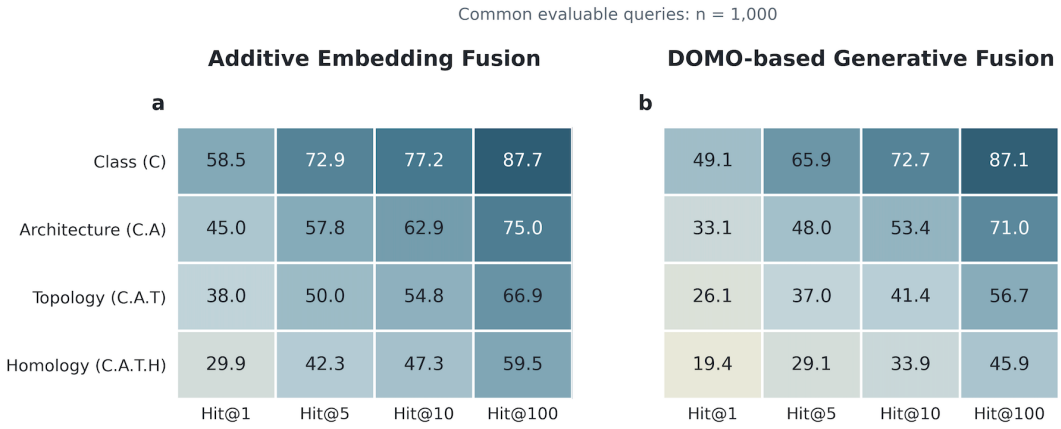


图 3: 旧版 Benchmark 上两种 Training-free 方法的 CATH 分层检索命中率。(a) Additive Embedding Fusion；(b) DOMO-based Generative Fusion。横轴为 Hit@K，纵轴为 CATH 分类层级，颜色表示命中率（%）。

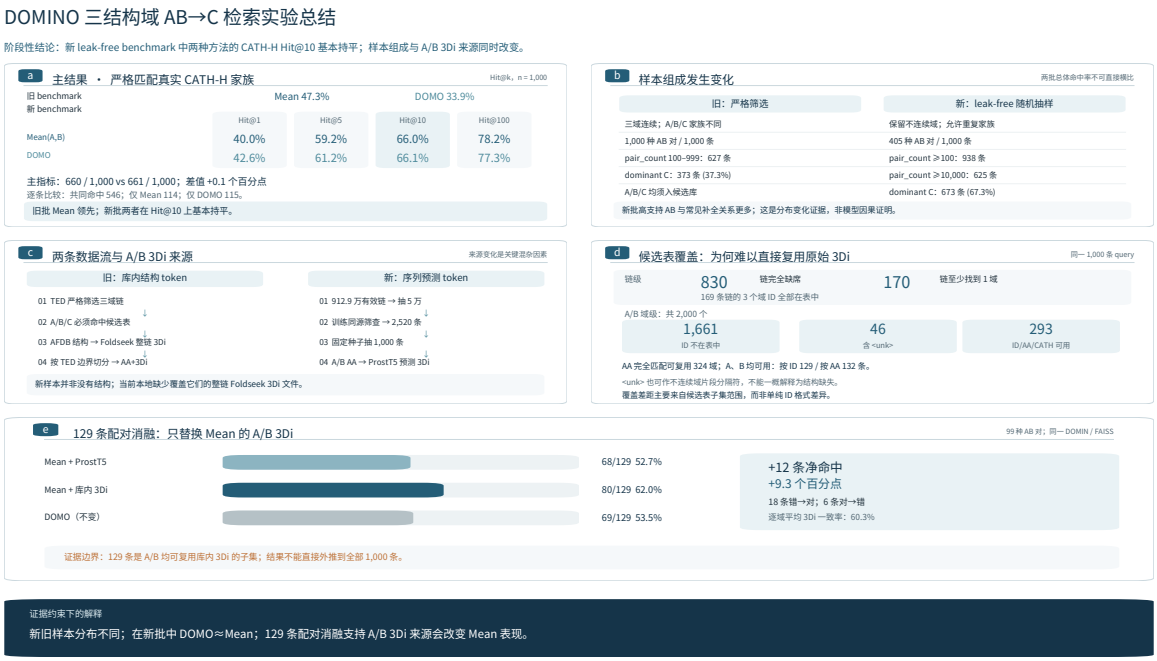


图 4: DOMINO 三结构域 AB→C 检索实验总结。(a) 新旧 Benchmark 的检索性能对比；(b) 测试集组成差异；(c) 两版数据处理流程与 A/B 结构字母来源；(d) 原始 3Di 表征的候选库覆盖情况；(e) 129 条配对样本上的 3Di 来源消融实验。

2.4 新旧 Benchmark 的构建差异与性能变化潜在原因

样本组成。 旧版 Benchmark 以 AB 家族对为抽样单位，包含 1,000 条查询及 1,000 种不同的 AB 家族对，要求三个结构域连续、CATH-H 家族两两不同，且 A/B/C 均存在于候选库中。新版则从经过训练来源同源筛查的蛋白链中抽样，1,000 条查询仅涉及 405 种 AB 家族对，允许不连续结构域及重复家族。

在 AB 共现支持度方面，旧版有 627 条查询的 AB support 位于 100–999，其余 373 条不低于 1,000；新版有 938 条查询的 AB support 不低于 100，其中 625 条达到 10,000 及以上。这表明新版样本明显集中于高频共现的 AB 家族对。

进一步考察第三域的条件共现分布，定义 dominant C 为给定 AB 时出现频率最高的 C 家族，以其条件频率是否超过 0.5 衡量共现集中程度。旧版有 373 条查询（37.3%）满足该条件，新版则有 673 条（67.3%），提高了 30.0 个百分点。

因此，新版 Benchmark 不仅包含更复杂的结构域组成，还明显提高了高支持度、由少数 C 家族主导的查询比例。这种样本分布变化可能影响第三域检索难度，是解释两版 Benchmark 性能差异的重要因素。

候选库覆盖、3Di 来源差异及配对消融实验。 旧版 Benchmark 要求 A/B/C 均存在于候选库中，直接使用基于 AFDB 预测结构、经 Foldseek 提取的库内 AA+3Di 表示。新版不要求结构域 ID 命中候选库，而是从天然序列提取 A/B，并使用 ProstT5 预测其 3Di。在新版 1,000 条查

询中，830 条至少有一个结构域缺少完整的库内表示，仅 170 条的三个结构域 ID 均可在候选表中找到。因此，两版 Benchmark 不仅存在候选库覆盖差异，A/B 查询侧的 3Di 来源也发生了变化。

为验证这一差异的影响，选取 129 条可同时获得两种 A/B 3Di 表示的查询进行配对消融，保持 DOMIN 编码器、FAISS 候选库及检索参数不变，仅替换 Additive Embedding Fusion 的 A/B 结构字母来源。

结果表明，使用 ProstT5 预测 3Di 时，严格 CATH-H Hit@10 为 52.7%（68/129）；使用基于 AFDB 结构的 Foldseek 3Di 后，提升至 62.0%（80/129），提高 9.3 个百分点。作为对照，DOMO-based 方法保持不变，Hit@10 为 53.5%（69/129）。配对比较中，18 条查询的命中状态发生变化，其中 12 条由未命中变为命中，6 条由命中变为未命中。这说明在该子集上，使用结构来源的原始 3Di 能够改善 Additive Embedding Fusion 的检索表现，3Di 来源差异可能是新旧 Benchmark 性能变化的重要因素之一。

此外，ProstT5 原始论文（Heinzinger et al., 2024）在 SCOPe40 结构域级同源检索实验中，直接利用结构域氨基酸序列预测 3Di 结构字母，再通过 Foldseek 进行检索。这说明 ProstT5 可以用于单个结构域的 3Di 预测，并不强制要求输入完整蛋白质链。

结论 检索结果的差异源于样本组成及输入结构表征的不同。此外 ProstT5 预测的 3Di token 与原始结构对应的 3Di token 不完全一致，这种表征差异使 Additive Embedding Fusion 的检索结果更差。

3 实验二：检索候选生成序列的 AlphaFold 结构评价

3.1 评价动机：家族命中相近但具体候选不同

在新版 1,000 条三结构域 Benchmark 中，Mean(A,B) 与 DOMO-based Generative Fusion 的 CATH-H Hit@10 分别为 66.0% 和 66.1%，总体表现几乎相同。然而，两种方法仅有 546 条查询同时命中，表明其逐查询检索结果存在差异。

进一步比较 Top-1 候选，两种方法的 CATH-H Hit@1 分别为 40.0% 和 42.6%。在相同的 1,000 条查询中，仅有 82 条检索到相同的候选域，其余 918 条对应不同的结构域实例。即使在两种方法均命中目标 CATH-H 家族的 281 条查询中，仍有 241 条选择了不同的候选域。

上述结果说明，CATH 家族命中率虽然能够衡量检索的家族一致性，却不足以反映不同候选域在后续完整蛋白生成中的结构表现。因此，有必要进一步引入 AlphaFold 3 结构评价，从蛋白质结构质量的角度比较两种 Training-free 方法。

3.2 实验数据与结构评价流程

本实验基于经过训练来源同源筛查的 1,000 条三结构域蛋白查询，进一步评价两种 Training-free 检索方法的下游蛋白设计质量。对于每条查询，固定天然来源结构域 A、B，分别采用 Additive Embedding Fusion（Mean）和 DOMO-based Generative Fusion 检索排名第一的候选域 C。随

后将 A、B 及各方法检索得到的 C 作为三个独立条件输入 DOMO，生成完整蛋白质序列，并使用 AlphaFold 3（AF3）进行单链结构预测。

两种方法各产生 1,000 条设计记录，共完成 2,000 个 AF3 预测任务，对应 1,916 条不同的生成序列。每个任务均选取 AF3 排名最高的预测结构用于评价。

评价指标包括：（1）Sequence Recovery，通过局部序列比对衡量三个输入域在生成序列中的保留程度；（2）平均 pLDDT，衡量全链局部结构预测置信度；（3）pTM，衡量整体结构预测置信度。此外，根据检索结果的 CATH-H 标签及天然三域共现记录，对不同类型的设计进行分组比较。

3.3 整体结构质量与天然结构恢复

两种方法在输入结构域序列恢复方面均表现较好。排除 53 条存在域匹配区间重叠、无法可靠分配三个输入域位置的任务后，Mean 和 DOMO-based 分别有 97.1%（949/977）和 96.4%（935/970）的设计达到平均 Sequence Recovery ≥ 0.9，表明 DOMO 通常能够较完整地保留给定的结构域序列。

在 AF3 预测结构质量方面，两种方法的整体表现接近。Mean 和 DOMO-based 的全链平均 pLDDT 中位数分别为 78.47 和 78.10，pTM 中位数均为 0.53。基于相同 A/B 查询的配对比较，两项指标的差值中位数均为 0，未观察到明显的整体优势。

进一步按照 Top-1 检索结果是否命中来源 C 的完整 CATH-H 家族进行分组。Mean 的 Hit/Miss 组 pTM 中位数分别为 0.54/0.52，DOMO-based 分别为 0.54/0.51，表明家族命中组的整体预测置信度略高，但差异有限。

需要指出的是，Sequence Recovery 衡量的是输入域氨基酸序列的保留程度，而 pLDDT 和 pTM 均为预测置信度指标。当前尚未通过与天然参考结构的结构比对计算 TM-score，因此上述结果不能直接视为天然三维结构的恢复。

3.4 未观测 CATH-H 三元组的结构质量分析

为探索两种方法对未观测结构域组合的设计能力，将输入 A、B 与检索得到的 C 所对应的完整 CATH-H 标签构成无序三元组，并与此前统计的 53,381 种天然已观测三元组进行比较。三个标签均完整且存在于参考集合中的组合定义为 Observed；标签完整但未出现的组合定义为 Unobserved；标签缺失或不完整的组合归为 Unknown。

Mean 的 1,000 条设计中，Observed、Unobserved 和 Unknown 分别为 565、49 和 386 条；DOMO-based 分别为 625、94 和 281 条。其中，Mean 的 49 条未观测设计对应 49 种不同三元组，DOMO-based 的 94 条对应 86 种不同三元组。

在完整注释的设计中，Mean 的 Observed/Unobserved 组平均 pLDDT 中位数分别为 78.56/79.50，DOMO-based 分别为 78.27/77.93。两种方法的 Observed 组 pTM 中位数均为 0.52，Unobserved 组均为 0.49。总体而言，未观测组合仍能够获得与已观测组合部分重叠的预测置信度分布，但其整体 pTM 略低。

进一步从各方法的 Unobserved 组中分别选择 pTM 最高的两个设计进行结构可视化。DOMO-

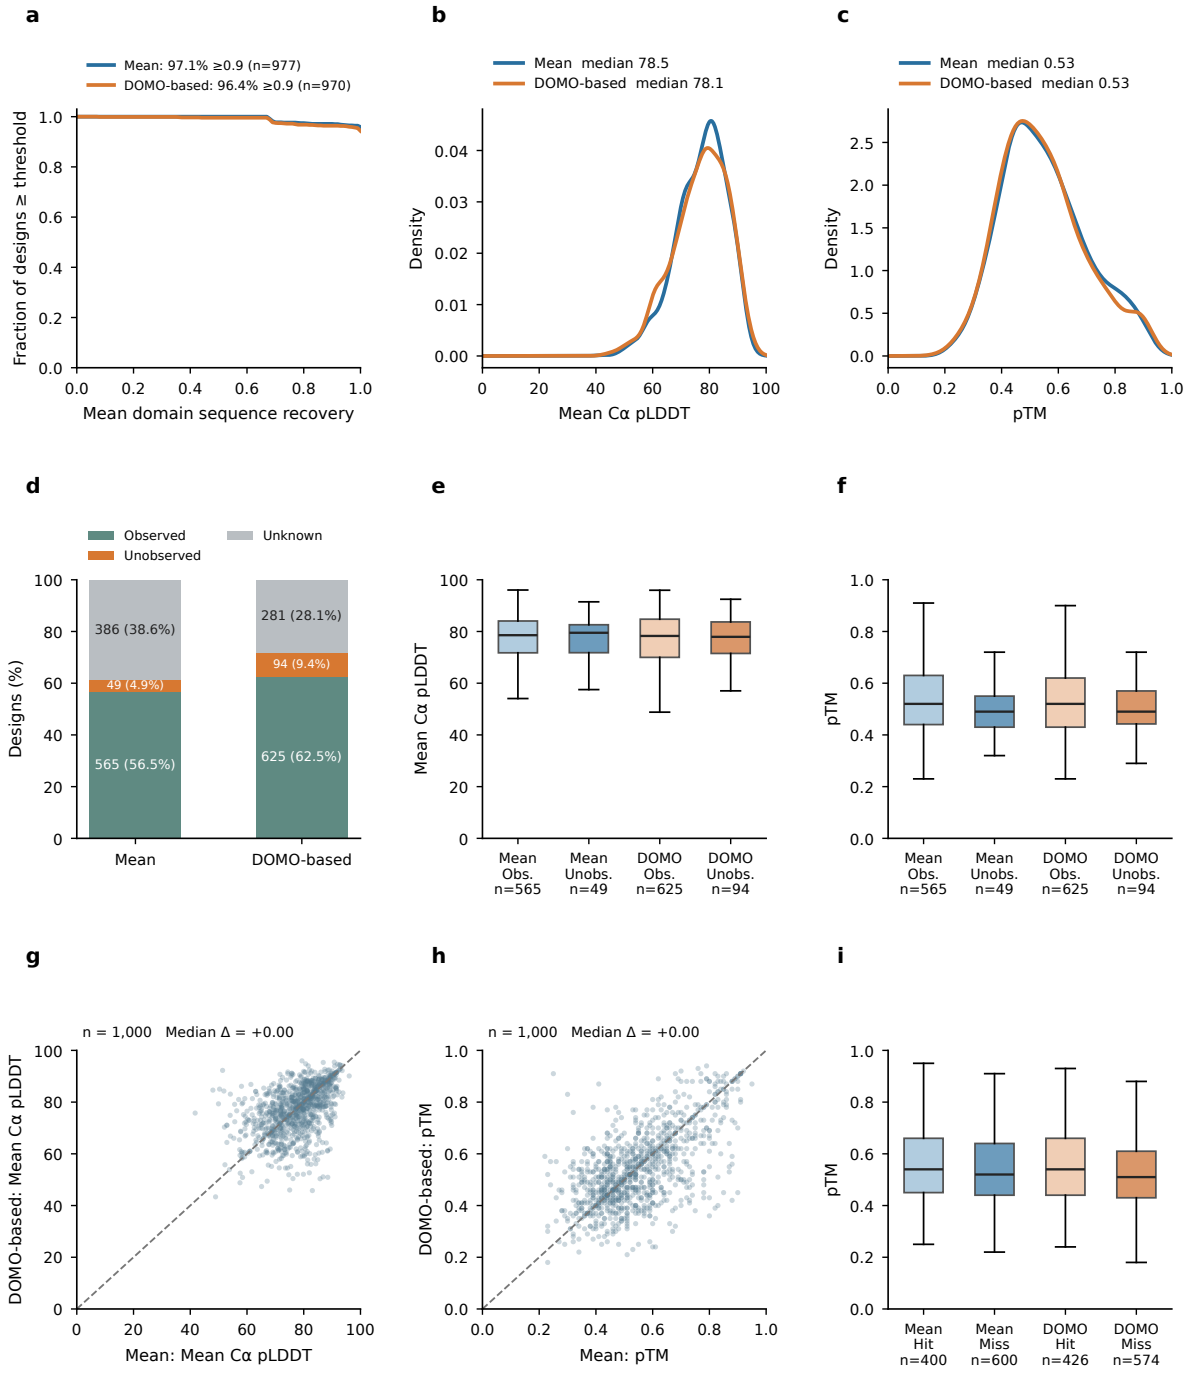


图 5: 两种 Training-free 检索方法的 AlphaFold 3 结构质量评价。(a–c) 展示两种方法的整体生成质量，包括结构域序列恢复率、平均 pLDDT 和 pTM 分布；(d–f) 展示已观测、未观测及标签未知的 CATH-H 三元组组成，并比较已观测与未观测组合的结构置信度；(g–i) 展示相同 AB 输入下两种方法的配对结构质量比较，以及不同 CATH-H Hit@1 分组的 pTM 分布。所有结构质量指标均基于每条设计的 AlphaFold 3 最高排名预测结构。

based 的两个代表性设计 pTM 分别为 0.82 和 0.81，Mean 分别为 0.72 和 0.70。四个案例均完整保留了输入结构域序列，部分设计还表现出结构域在生成序列中的排列顺序变化。

上述结果说明，部分未出现在当前 TED/CATH 共现参考集合中的三域家族组合，仍可生成具有较高 AF3 预测置信度的蛋白质结构。然而，未观测并不代表自然界不存在，较高的预测置信度也不能直接证明其结构稳定性、功能或实验可实现性。

3.5 代表性结构与案例展示

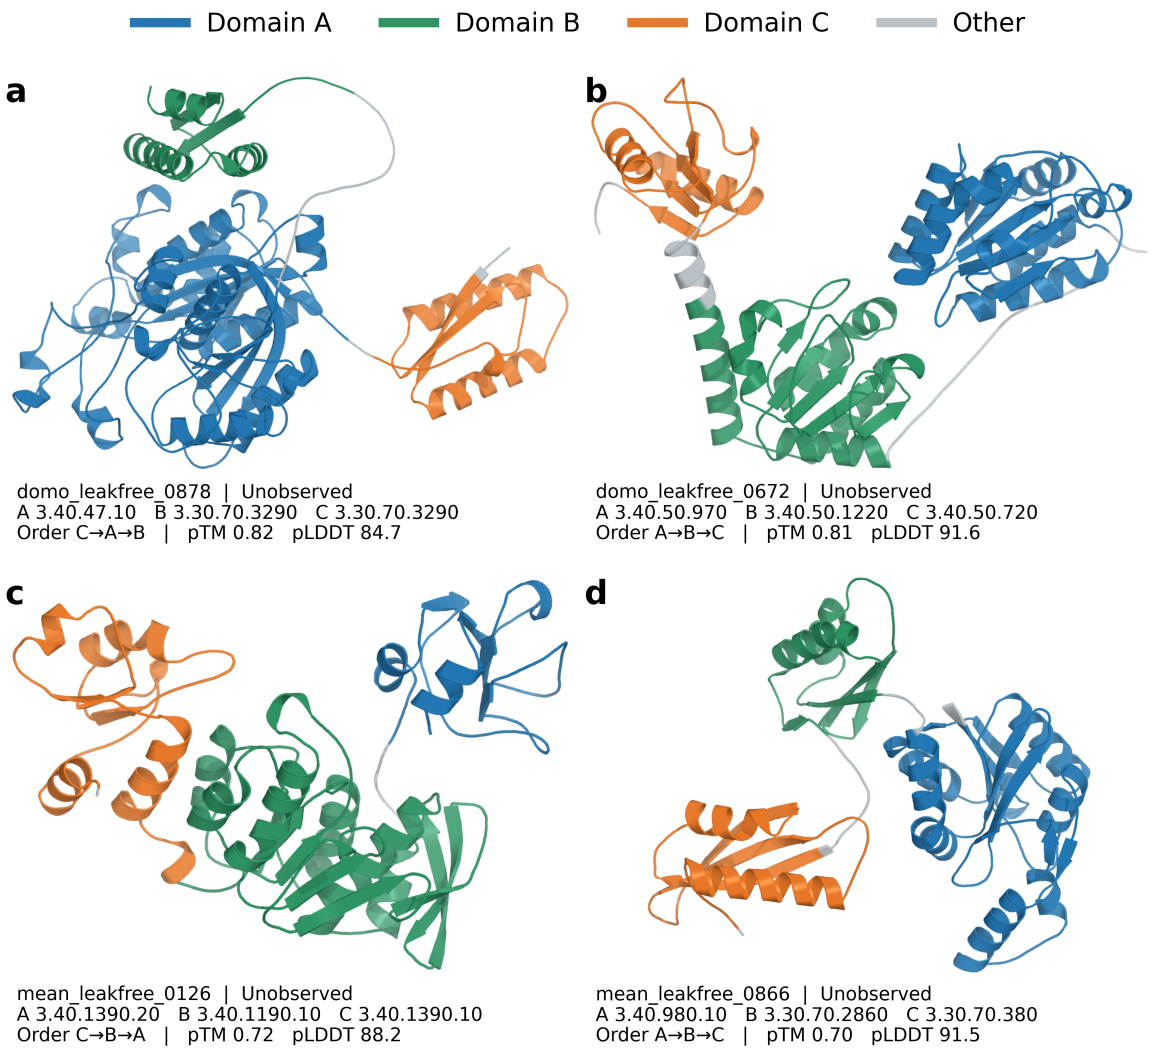


图 6: 未观测 CATH-H 三结构域家族组合的代表性蛋白质设计。从两种 Training-free 检索方法生成的 2,000 条蛋白质中，分别选取两个具有较高 AlphaFold 3 预测置信度的未观测三元组案例。这些案例展示了未观测家族组合仍可形成高置信度的预测结构，且部分设计呈现不同于输入顺序的结构域排列。

3.5.1 DOMO-based：domo_leakfree_0878

该设计对应的 CATH-H 三元组为 (3.40.47.10, 3.30.70.3290, 3.30.70.3290)，其中 B 与 C 属于相同同源超家族。AF3 预测结果的平均 pLDDT 为 84.70，pTM 为 0.82，在 DOMO-based 的 94 条未观测设计中排名第一。三个输入域的序列均被完整保留，在生成蛋白中的排列顺序为 C–A–B，表明 DOMO 能够在保留输入域序列的同时调整其排列顺序。

Foldseek 结构相似性分析 最佳匹配为 MGnify ESM30 数据库中的 MGYP000358131017(Probability = 1.00，Sequence Identity = 34.5%，E-value = 8.13×10^{-55})。其他显著匹配主要涉及聚酮合酶（Polyketide synthase)、酰基转移酶（Acyltransferase）及相关结构域，表明该设计与已知蛋白存在显著的局部结构相似性。

BLAST 序列相似性分析 该设计蛋白全长 598 aa，UniRef100 最佳匹配为 A0A226D6W6，对应 Folsomia candida 的 β-酮酰-ACP 合酶 I。BLAST 比对覆盖生成序列的第 88–598 位，在 511 个比对位置中有 495 个残基一致，Identity 达到 97%，E-value 为 0.0，查询覆盖率约为 85.5%。

结果表明，该设计的大部分序列与已知天然蛋白高度相似，整体序列新颖性有限。

ProtParam 理化性质分析 该设计蛋白全长 598 aa，理论分子量为 64.51 kDa，理论等电点（pI）为 7.98，呈弱碱性特征。ExPASy ProtParam 计算得到的不稳定性指数（Instability Index）为 39.34，略低于经验阈值 40，被归类为预测稳定蛋白。其脂肪族指数（Aliphatic Index）为 97.64，平均疏水性指数（GRAVY）为 -0.027，表明整体平均疏水性接近中性。

结合此前 AF3 预测结果，该设计的平均 pLDDT 为 84.70，pTM 为 0.82，同时具有较高的结构预测置信度和低于经验阈值的不稳定性指数。

3.5.2 DOMO-based：domo_leakfree_0672

该设计的 CATH-H 三元组为 (3.40.50.970, 3.40.50.1220, 3.40.50.720)，三个结构域分别属于不同的同源超家族。AF3 预测的平均 pLDDT 为 91.59，pTM 为 0.81，在 DOMO-based 未观测组中排名第二。三个输入域均被完整保留，排列顺序为 A–B–C。该案例同时具有较高的局部与整体结构预测置信度。

Foldseek 结构相似性分析 最佳匹配为 MGnify ESM30 数据库中的 MGYP000337508443(Probability = 1.00，Sequence Identity = 41.5%，E-value = 1.87×10^{-32})。其他显著匹配主要集中于硫胺素焦磷酸（Thiamine pyrophosphate, TPP）结合蛋白、乙酰乳酸合酶（Acetolactate synthase）及苯甲酰甲酸脱羧酶（Benzoylformate decarboxylase)，提示该设计与已知 TPP 依赖性酶具有局部结构相似性。

BLAST 序列相似性分析 该设计蛋白全长 450 aa，UniRef100 最佳匹配为 A0A1H0ENH4，对应苯甲酰甲酸脱羧酶/ 乙酰乳酸合酶相关蛋白。BLAST 比对的 Identity 为 94%（332/354)，主要覆盖生成序列的第 5–346 位，查询覆盖率约为 76.0%，E-value 为 0.0。

该结果说明，约四分之三的设计序列与已知天然蛋白具有较高同源性。其余未被最佳匹配覆盖的序列区域可能包含额外引入的结构域或连接片段。

ProtParam 理化性质分析 该设计蛋白全长 450 aa，理论分子量为 47.91 kDa，理论等电点（pI）为 5.15，呈酸性特征。ProtParam 计算得到的不稳定性指数为 42.48，略高于经验阈值 40，因此被归类为预测不稳定蛋白。其脂肪族指数为 98.33，平均疏水性指数（GRAVY）为 0.151，是四个代表性设计中唯一 GRAVY 为正的蛋白，表明其整体平均疏水性相对较高。

值得注意的是，该设计的 AF3 平均 pLDDT 为 91.59，pTM 为 0.81，均表现出较高的结构预测置信度，但其 ProtParam 不稳定性指数略高于经验阈值。

3.5.3 Mean：mean_leakfree_0126

该设计的 CATH-H 三元组为 (3.40.1390.20, 3.40.1190.10, 3.40.1390.10)。AF3 预测的平均 pLDDT 为 88.22，pTM 为 0.72，在 Mean 的 49 条未观测设计中排名第一。三个输入域均被完整保留，但生成序列中的排列顺序为 C–B–A。该结果表明，简单的 Embedding 融合方法检索得到的候选域，同样能够通过 DOMO 生成具有较高预测置信度的三结构域蛋白。

Foldseek 结构相似性分析 最佳匹配为 MGnify ESM30 数据库中的 MGYP000760773777(Probability = 1.00，Sequence Identity = 31.2%，E-value = 7.28×10^{-29})。其他显著匹配高度集中于 UDP-N-acetylmuramoyl-tripeptide–D-alanyl-D-alanine ligase （MurF），该酶参与细菌肽聚糖生物合成。结果表明该设计与已知 MurF 相关蛋白存在显著的局部结构相似性。

BLAST 序列相似性分析 该设计蛋白全长 410 aa，UniRef100 最佳匹配为 A0A179SSF3，对应 MurF 类连接酶，最佳匹配 E-value 为 3×10^{-135}。BLAST 检测到两个主要高分片段对（HSP）：第一个覆盖生成序列的第 58–319 位，Identity 为 84%（219/262）；第二个覆盖第 319–410 位，Identity 达到 100%（92/92）。

值得注意的是，第二个 HSP 对应天然蛋白的第 3–94 位，而第一个 HSP 主要对应天然蛋白的第 60–318 位。这表明天然蛋白前部的高同源性片段在设计序列中出现在后部，提示可能存在序列片段重排现象。

结合此前观察到的 C–B–A 结构域排列顺序，该案例值得进一步开展残基映射与结构叠合分析，以判断其是否具有类似 circular permutation 的序列组织特征。

ProtParam 理化性质分析 该设计蛋白全长 410 aa，理论分子量为 46.62 kDa，理论等电点（pI）为 8.91，是四个代表性设计中理论等电点最高的蛋白，具有较明显的碱性特征。ProtParam 计算得到的不稳定性指数为 27.62，明显低于经验阈值 40，也是四个设计中该指数最低的蛋白，被归类为预测稳定蛋白。其脂肪族指数为 96.68，平均疏水性指数（GRAVY）为 -0.203，表明整体平均偏亲水。

结合 AF3 预测结果，该设计的平均 pLDDT 为 88.22，pTM 为 0.72，具有较高的局部结构预测置信度。其较低的不稳定性指数提供了补充性的序列经验评价。

3.5.4 Mean：mean_leakfree_0866

该设计的 CATH-H 三元组为 (3.40.980.10, 3.30.70.2860, 3.30.70.380)。AF3 预测的平均 pLDDT 为 91.47，pTM 为 0.70，在 Mean 未观测组中按 pTM 排名第二，其平均 pLDDT 则位列该组第一。三个输入域均被完整保留，排列顺序为 A–B–C。该案例进一步说明，未观测的结构域家族组合也可能获得较高的局部结构预测置信度。

Foldseek 结构相似性分析 最佳匹配为 AFDB50 数据库中 Bdellovibrio sp. 的 Competence/damage-inducible protein A （AF-A0A924UJ69-F1-model_v6，Probability = 1.00，Sequence Identity = 55.7%，E-value = 2.74×10^{-38}）。其他显著匹配主要涉及 CinA 及 MoaB/Mog 相关蛋白，表明该设计与已知蛋白存在显著的局部结构相似性。

BLAST 序列相似性分析 该设计蛋白全长 351 aa，UniRef100 最高得分匹配为 A0ABT6DMG0，对应 CinA 类蛋白。BLAST 比对覆盖生成序列的第 1–336 位，查询覆盖率约为 95.7%。在 355 个比对位置中有 160 个残基一致，Identity 为 45%，E-value 为 6×10^{-93}。

与前三个案例相比，该设计虽然仍具有显著的天然序列同源性，但序列一致性明显降低，表现出相对更大的序列差异。因此，该案例更适合用于分析具有较大序列变化的三结构域组合能否保持合理的预测折叠。

ProtParam 理化性质分析 该设计蛋白全长 351 aa，理论分子量为 39.71 kDa，理论等电点（pI）为 5.24，呈酸性特征。ProtParam 计算得到的不稳定性指数为 35.01，低于经验阈值 40，被归类为预测稳定蛋白。其脂肪族指数为 87.98，平均疏水性指数（GRAVY）为 -0.364，是四个代表性设计中 GRAVY 最低的蛋白，表现出相对较强的整体亲水性。

结合 AF3 预测结果，该设计的平均 pLDDT 为 91.47，pTM 为 0.70，表明其局部结构具有较高的预测置信度。此前 BLAST 分析显示，该设计与最佳天然序列匹配具有相对较低的序列一致性。ProtParam 结果进一步提供了其基本理化性质的计算表征。

3.6 代表性设计蛋白的综合分析

综合结论 四个代表性设计均属于当前 TED/CATH 参考集合中未观测到的 CATH-H 三元组组合，且均获得了较高的 AF3 预测置信度（平均 pLDDT 为 84.70–91.59，pTM 为 0.70–0.82）。Foldseek 与 BLAST 分析表明，这些设计与已知蛋白存在显著的局部结构及序列相似性，其中 DOMO-0878 和 DOMO-0672 具有较长的高一致性序列片段，Mean-0126 呈现潜在的序列片段重排现象，Mean-0866 则表现出相对更大的序列差异。

ProtParam 分析显示，四个设计具有不同的理论等电点和平均疏水性，其中三个设计的不稳定性指数低于经验阈值 40。总体而言，现有结果表明，未观测的结构域家族组合可以通过 DOMO 生成具有较高预测结构置信度的完整蛋白序列。然而，当前证据主要支持参考集合层面的组合新颖性，尚不能证明全长结构新颖性、实际折叠稳定性或生物学功能。

表 1: 四个代表性未观测 CATH-H 三元组设计蛋白的结构、序列相似性及理化性质比较。

指标	DOMO-0878	DOMO-0672	Mean-0126	Mean-0866
Sequence length (aa)	598	450	410	351
Domain order	C–A–B	A–B–C	C–B–A	A–B–C
AF3 mean pLDDT	84.70	91.59	88.22	91.47
AF3 pTM	0.82	0.81	0.72	0.70
Foldseek database	MGnify ESM30	MGnify ESM30	MGnify ESM30	AFDB50
Foldseek identity (%)	34.5	41.5	31.2	55.7
Foldseek E-value	8.13×10^{-55}	1.87×10^{-32}	7.28×10^{-29}	2.74×10^{-38}
BLAST best hit	A0A226D6W6	A0A1H0ENH4	A0A179SSF3	A0ABT6DMG0
BLAST identity (%)	97	94	84 / 100	45
BLAST query coverage (%)	85.5	76.0	∼86.1	95.7
Molecular weight (kDa)	64.51	47.91	46.62	39.71
Theoretical pI	7.98	5.15	8.91	5.24
Instability index	39.34	42.48	27.62	35.01
Aliphatic index	97.64	98.33	96.68	87.98
GRAVY	-0.027	0.151	-0.203	-0.364
ProtParam classification	Stable	Unstable	Stable	Stable

注：Foldseek identity 为最佳结构比对的局部序列一致性，不代表全长结构相似度。BLAST identity 同样基于局部序列比对；Mean-0126 包含两个 HSP，分别报告其一致性，覆盖率按查询区间近似统计。ProtParam 稳定性分类基于不稳定性指数的经验阈值，不代表实验测得的蛋白稳定性。

4 阶段性总结与下一步计划

4.1 现有方法的计算开销与多方向补全局限

当前两种 Training-free 方法在新版 Benchmark 上的 CATH-H Hit@10 分别为 66.0% 和 66.1%，下游 AF3 预测结构置信度也基本接近。然而，DOMO-based Generative Fusion 需要额外执行 DOMO 序列生成、ProstT5 结构字母预测及 DOMIN 编码，其计算流程明显复杂于直接进行 Embedding 加和的方案。因此，在尚未获得明确性能收益的情况下，额外的推理开销构成了该方法的潜在劣势。

此外，现有 Benchmark 仅考虑 AB→C，尚未评价 AC→B 和 BC→A。对于 AC→B，DOMO-based 方法需要根据两个非相邻输入域生成融合序列，再将其编码为第三域检索查询。生成序列的域排列及连接区域可能影响联合表征的有效性，因此其表现未必优于简单的向量加和。

另一方面，结构字母来源也是影响检索性能的重要因素。此前消融实验表明，ProstT5 预测的 3Di 与结构来源 3Di 能够产生不同的检索结果。虽然使用结构预测模型可以获得结构来源的 3Di，但额外的结构预测开销限制了其在大规模在线检索中的适用性。

下一步将复用现有 1,000 条测试蛋白，开展 AB→C、AC→B 和 BC→A 的三方向补全实验，并记录不同方法的推理耗时及检索性能。重点分析生成式融合能否在更一般的补全任务中取得足以抵消额外计算成本的性能收益，从而判断其相对于简单 Embedding Fusion 的实际价值。

4.2 现有 Benchmark 的任务局限与三方向补全计划

当前 Benchmark 仅考虑固定的 AB→C 任务，即按照 TED 注释顺序选取前两个结构域作为输入，检索第三个结构域。然而，同一条三结构域蛋白实际上可以构造三种不同的补全任务：

$$(A, B) \to C, \qquad (A, C) \to B, \qquad (B, C) \to A. \tag{5}$$

现有评测尚未考虑输入结构域选择对检索性能的影响。对于 Additive Embedding Fusion，虽然向量加和具有输入顺序不变性，但不同输入域组合会产生不同的联合查询表示。对于 DOMO-based Generative Fusion，不同结构域组合还可能影响中间序列的生成及其编码结果。因此，仅凭 AB→C 的结果，尚不能判断两种方法在其他补全方向上的表现。

下一步计划直接复用现有经过训练来源同源筛查的 1,000 条三结构域蛋白，构建 Three-way Leave-one-domain-out Benchmark。每条蛋白分别生成 AB→C、AC→B 和 BC→A 三种任务，共形成 3,000 条补全查询。两种方法分别进行检索，合计 6,000 条方法–查询评测记录，其中已有 2,000 条，仅需新增 4,000 条。

实验将保持来源蛋白、候选库、结构字母预测方式及检索参数一致，分别报告三种任务在 CATH-H 层级的 Hit@K，并通过同一来源蛋白内的配对比较，分析补全目标变化对两种融合方法的影响。

该实验旨在检验当前方法的性能是否依赖于固定的 AB→C 任务设定，并为后续支持任意输入结构域组合的多结构域补全模型提供更全面的评价依据。

4.3 未共现组合数据集的实施计划

目前的 Benchmark 主要基于天然已观测的三结构域蛋白，通过固定 A/B 检索第三域 C，并评价检索结果的家族一致性及生成蛋白的预测结构质量。然而，天然共现数据仅覆盖可能结构域组合空间中的一小部分，因此后续计划进一步扩展至未观测的 AB 家族对，探索模型在缺少天然共现参考条件下的结构域组合能力。

整体流程如图 7 所示。首先，从已有结构域库中选取初始结构域 A，利用 DOMIN 检索候选结构域 B，形成双结构域组合 (A,B)。根据 TED/CATH 共现统计，将其划分为已观测和未观测 AB，重点保留具有完整 CATH-H 注释、但未出现在现有共现记录中的组合。对于候选 AB，分别使用 Additive Embedding Fusion 和 DOMO-based Generative Fusion 检索第三域 C，形成完整的三域设计条件。

评价阶段采用两类互补指标。对于具有天然共现参考的组合，继续使用 CATH 分层 Hit@K 衡量检索表现；对于未观测组合，由于缺少直接的天然第三域标签，主要通过 DOMO 生成完整序列，并使用 AlphaFold 3 评价平均 pLDDT、pTM 及域间 PAE 等预测结构指标。同时结合 Sequence Recovery、BLAST 和 Foldseek，检查输入域保留程度及与已知蛋白的序列、结构相似性。

在数据实施方面，计划采用固定随机种子和确定性抽样，控制不同 AB 家族对的出现频率，避免测试集过度集中于少数高频家族。同时对已观测与未观测组合使用一致的生成和结构预测流程，并记录家族重复、结构域长度及注释完整性等因素，为后续分层分析提供依据。

该实验将从已有天然三域蛋白的第三域恢复，进一步扩展到未观测结构域组合的计算探索，并为未来递归组装更多结构域提供基础。需要强调的是，未观测仅表示组合未出现在当前参考集合中，AF3 预测置信度也不能直接证明其生物学兼容性或实验稳定性。

4.4 新版 Benchmark 的改进与现有结论

本周主要完成了检索 Benchmark 的数据构建改进，以及两种 Training-free 方法的下游结构评价。

首先，在数据质量控制方面，通过恢复 DOMIN 训练来源蛋白的全长序列，构建 MMseqs2 同源性筛查流程。从具有完整 CATH-H 注释的三结构域蛋白中初步抽取 50,000 条候选链，排除 47,480 条达到预设同源阈值的序列，最终从剩余 2,520 条中抽取 1,000 条构建新版 Benchmark。该流程降低了与已识别训练来源序列高度同源的风险，但不能保证完全排除所有潜在的数据重叠。

其次，新版 Benchmark 放宽了连续结构域、家族两两不同及候选库精确覆盖等限制，从原先的 1,000 种不同 AB 家族对，调整为 1,000 条来源蛋白链、405 种 AB 家族对。与此同时，两种检索方法统一使用 ProstT5 预测查询侧 3Di，提高了输入表征来源的一致性。

在新版 Benchmark 上，Additive Embedding Fusion 与 DOMO-based Generative Fusion 的严格 CATH-H Hit@10 分别为 66.0% 和 66.1%，与旧版的 47.3% 和 33.9% 形成明显对比。进一步分析发现，新版查询更加集中于高支持度、由少数第三域家族主导的 AB 组合。此外，在 129 条配对查询的消融实验中，将 Additive Embedding Fusion 的 3Di 来源由 ProstT5 预测替换为基于结构提取的 Foldseek 3Di，Hit@10 从 52.7% 提升至 62.0%。这些结果表明，样本分布与输入结构表征均可能显著影响两种方法的相对检索表现，因此新旧 Benchmark 的结果不宜直接视为同一条件下的方法优劣比较。

在结构评价方面，两种方法分别检索 Top-1 C，并通过相同的 DOMO 生成流程构建完整蛋白，共完成 2,000 个 AF3 预测任务。两组的平均 pLDDT 中位数分别为 78.47 和 78.10，pTM 中位数均为 0.53，未观察到明显的整体预测结构置信度优势。同时，两种方法均能够较完整地保留输入结构域序列。

进一步分析未观测 CATH-H 三元组，Mean 和 DOMO-based 分别获得 49 和 94 条标签完整且未出现在参考集合中的设计记录。两组未观测设计的 pTM 中位数均为 0.49，表明部分未观测组合仍能够获得一定的整体结构预测置信度。

针对四个代表性案例，结合 AF3、Foldseek、BLAST 及 ProtParam 进行综合分析。结果显示，部分设计虽然具有较高的 AF3 预测置信度，但仍与已知天然蛋白存在较长的高同源性序列片段；其中一条设计还表现出潜在的序列重排现象。因此，当前结果主要支持参考集合层面的结构域家族组合探索，尚不能直接证明全长序列或整体结构的新颖性。

总体而言，本周建立了经过训练来源同源筛查的三结构域检索 Benchmark，完成了从第三域检索、完整序列生成到 AF3 结构评价的统一流程。现阶段尚未发现复杂的生成式融合方法在检索准确率或预测结构置信度方面具有稳定优势。后续将重点构建未共现 AB 组合测试集，进一步检验不同融合策略对未观测结构域组合的适用性，并在统一评价条件下探索更有效的多结构域补全方法。

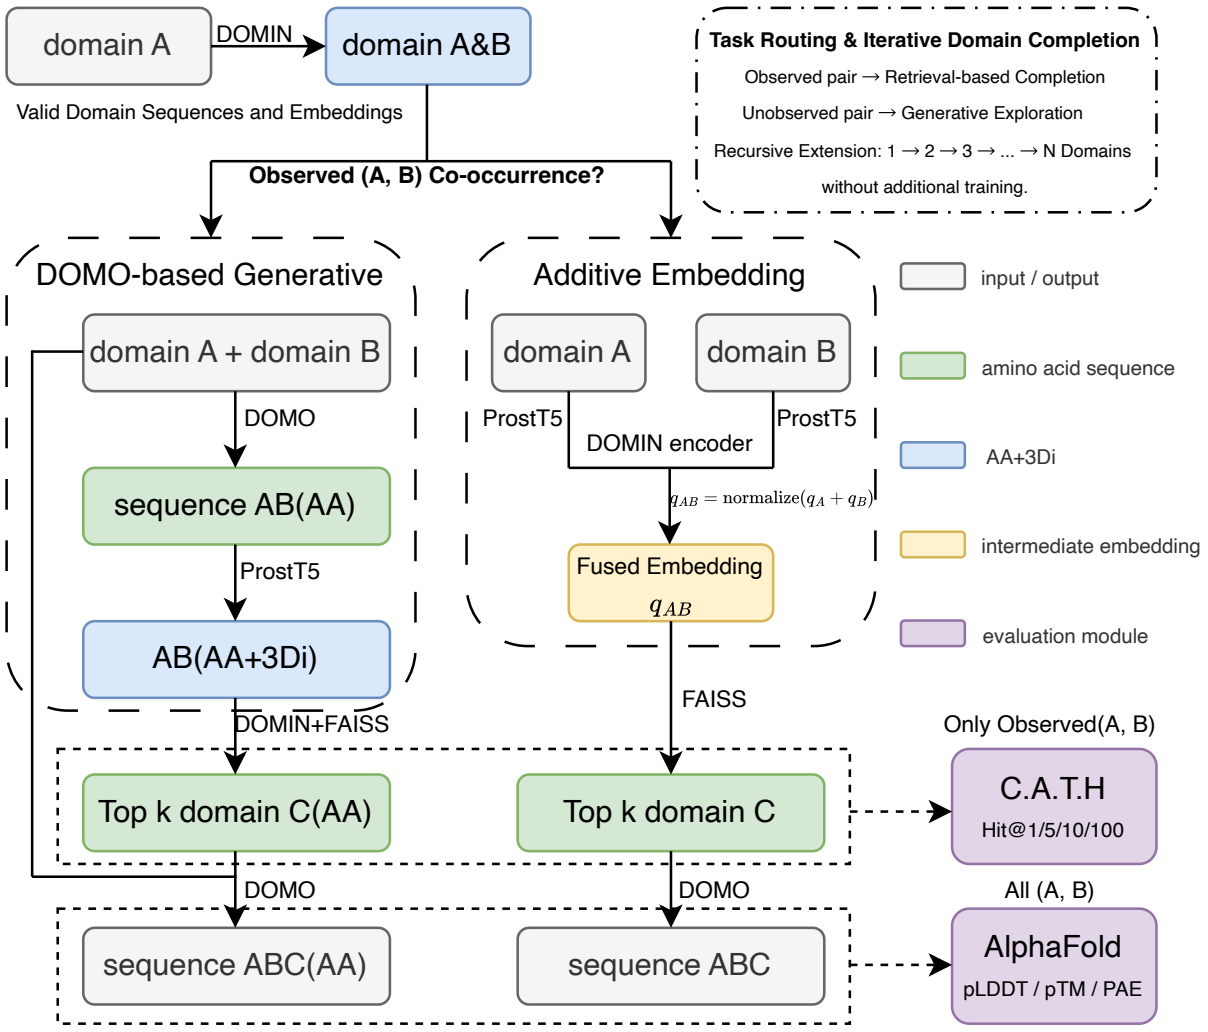


图 7: 基于 Training-free 方法的迭代式多结构域蛋白质组装框架。首先，以单个结构域 A 为输入，通过 DOMIN 检索结构域 B，构建双结构域组合 (A, B)，并根据 TED/CATH 数据判断该结构域对是否存在已观测共现记录。随后，采用两种无需额外训练的第三域检索方法：Additive Embedding Fusion 分别编码 A、B 并通过向量加和构建联合查询表示；DOMO-based Generative Fusion 则利用 DOMO 生成融合序列，通过 ProstT5 预测 3Di 结构字母，再使用 DOMIN 构建查询表示。两种方法均通过 FAISS 检索候选第三域 C。对于具有天然共现参考的查询，采用 CATH 四级分类下的 Hit@K 评价检索表现；对于候选三域组合，则通过 DOMO 生成完整序列，并利用 AlphaFold 的 pLDDT、pTM 和 PAE 等指标进行结构评价。该框架旨在结合已观测共现检索与未观测组合探索，为后续递归扩展至更多结构域提供基础。

A 数据构建流程补充材料

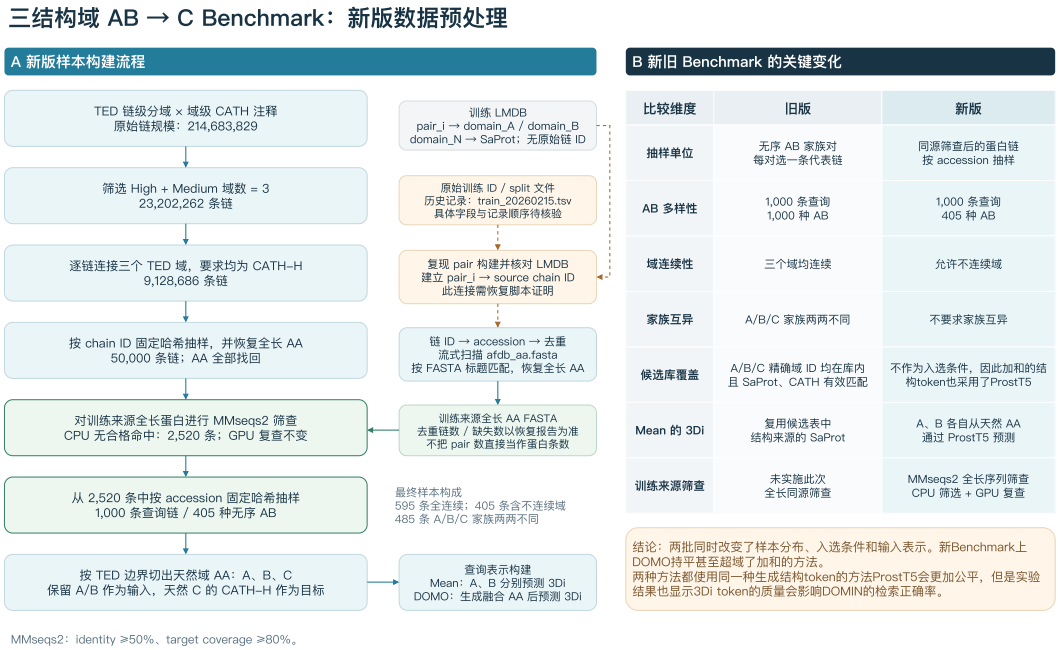


图 8: 新版数据流程与新旧对比

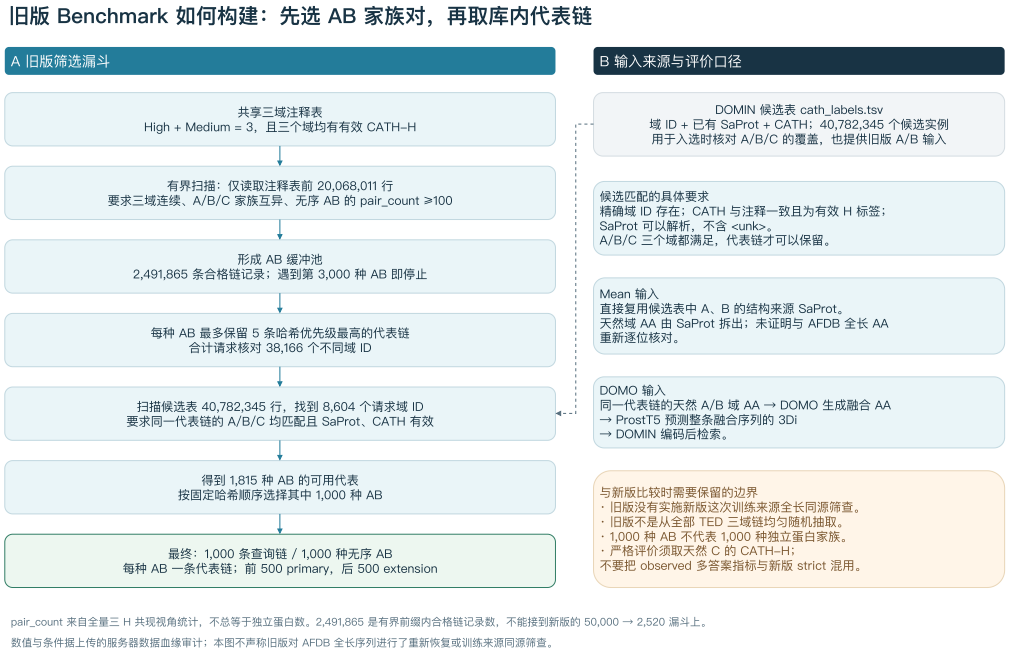


图 9: 旧版构建流程

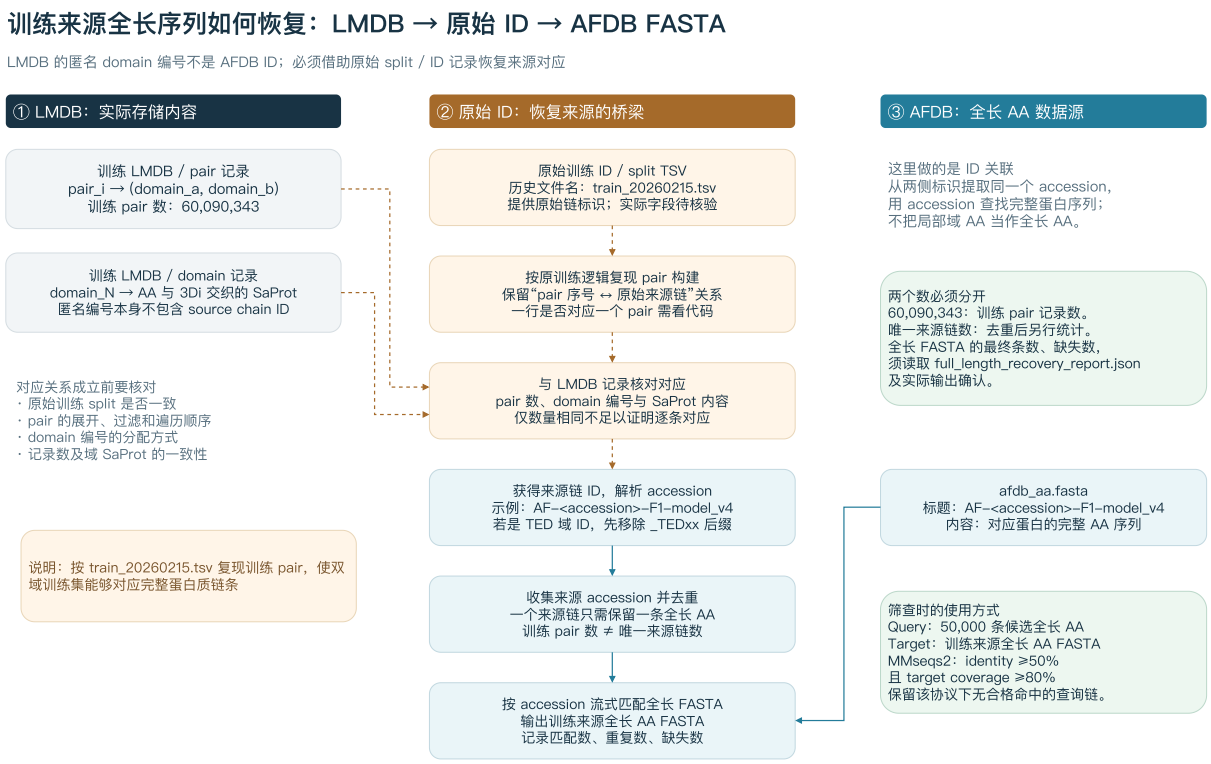


图 10: 训练集到全长序列