四种 Training-free 方法的 Benchmark 构建

姚昌铭

2026 年 11 月 9 日

目录

1 研究背景与工作目标 **3**

1.1 DOMINO 三结构域扩展的研究目标 3

1.2 本阶段研究问题与工作内容 3

2 Training-free Benchmark 设计与方法 **3**

2.1 AB→C 检索任务定义 3

2.2 数据来源与三结构域数据集构建 4

2.3 四种 Training-free 检索方法 5

2.3.1 Native 3Di Embedding Addition 5

2.3.2 Predicted 3Di Embedding Addition 5

2.3.3 DOMO Fusion with Predicted 3Di 6

2.3.4 DOMO Fusion with Sequence-only Input 6

2.4 Benchmark 构建与检索实现 7

2.5 CATH 递进式宏平均评价指标 7

3 大规模候选库检索实验：40.78M IVF **8**

3.1 实验设置 8

3.2 四种方法的 Top-1 检索性能比较 8

3.3 实验结果分析 8

4 闭合候选库检索实验：30K Exact Search **9**

4.1 闭合候选库构建与实验设置 9

4.2 四种方法的 Rank 1–10 检索表现 9

4.3 H-level 检索排名分析 10

4.4 两种候选库设置下的结果比较 10

5 总结与讨论 **11**

5.1 主要实验发现 11

5.2 结构表征质量与融合策略的影响 12

5.3 候选库构成与检索评价的影响 12

5.4 阶段性结论与后续工作 12

1 研究背景与工作目标

1.1 DOMINO 三结构域扩展的研究目标

DOMINO 主要围绕多结构域蛋白质的序列融合与结构生成展开。在此前双结构域研究的基础上，本阶段将研究范围扩展至三结构域蛋白质，重点探索给定两个结构域 A、B 时，如何从候选结构域集合中检索与其共同组成天然三结构域蛋白质的第三个结构域 C。

本阶段的主要目标包括：首先，分析 TED 数据集中三结构域蛋白质的规模、结构域排列及 CATH 家族组合特征；其次，将双结构域到第三结构域的检索任务定义为 AB→C，构建不依赖额外训练的检索 Benchmark；最后，通过不同结构 Token 来源及融合策略的比较，分析结构表征质量对多结构域检索性能的影响。

1.2 本阶段研究问题与工作内容

本阶段主要围绕以下三个问题展开：

1. 三结构域蛋白质在 CATH 分类体系下具有怎样的组合分布，相同的 AB 输入能够对应多少种不同的第三结构域?
2. 不同结构表征来源与融合策略如何影响 AB→C 检索性能?特别是原始 3Di Token、ProstT5 预测的 3Di Token 以及 DOMO 生成式融合之间存在怎样的差异?
3. 在大规模 FAISS IVF 候选库与 30K 闭合候选库两种设置下，四种方法是否能够保持相对一致的性能关系?

围绕上述问题，本阶段完成了三结构域数据筛选、共同测试集冻结、四种 Training-free Pipeline 实现，以及两种候选库下的检索评价。

2 Training-free Benchmark 设计与方法

2.1 AB→C 检索任务定义

本研究将三结构域检索任务定义为 AB→C：给定两个结构域 A 和 B，从候选结构域集合中检索与其共同组成天然三结构域蛋白质的第三个结构域 C。

对于第 i 条查询，其输入为：

$$Q_i = (A_i, B_i)$$

对应的真实答案为 C_i^*。检索方法分别构建查询表示 $\mathbf{q}_i$ 与候选结构域表示 $\mathbf{d}_j$，通过内积计算相似度：

$$s(Q_i, D_j) = \mathbf{q}_i^\top \mathbf{d}_j$$

随后按照相似度由高到低排序，获得候选结构域排名。

本研究重点比较不同查询表示构建方式的检索表现，而不对四种方法额外进行任务特定的模型训练。

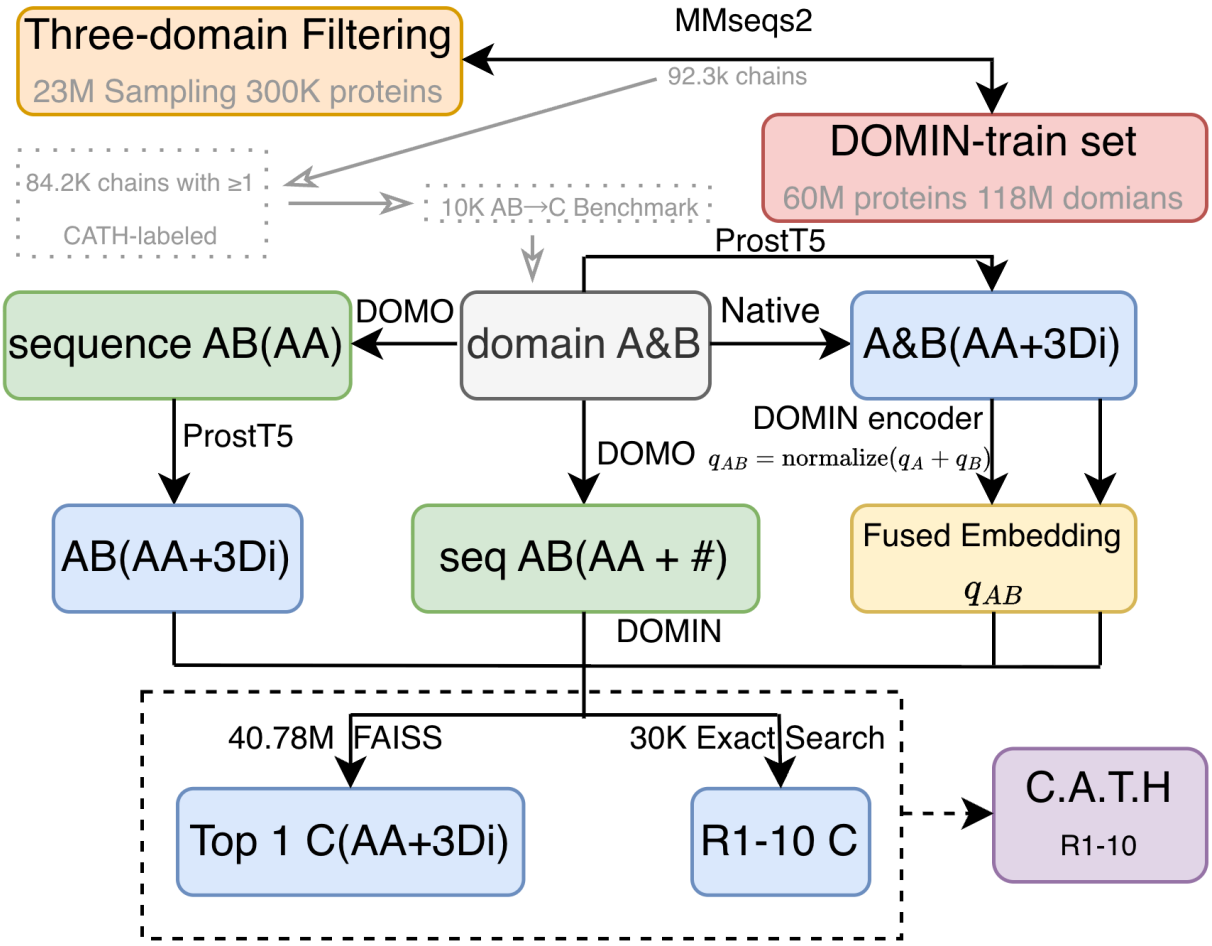


图 1: Three-domain Dataset Construction and Evaluation Framework. 展示三结构域数据集的抽样、MMseqs2 同源筛查、共同 Benchmark 构建、四种 Training-free 检索方法及两种候选库下的 CATH 评价流程。

2.2 数据来源与三结构域数据集构建

本研究以 TED 三结构域数据为基础，首先从 23,202,262 条恰好包含三个结构域的蛋白质链中，使用固定随机种子 20261105，按照链 ID 的 SHA-256 优先级无放回抽取 300,000 条链。

为控制与已有双结构域训练数据之间的潜在同源关系，进一步使用 MMseqs2 对抽样链的全长氨基酸序列进行筛查。目标数据库包含 60,090,343 条双结构域训练序列，主要参数如下：

```
--min-seq-id 0.5
-c 0.8
--cov-mode 0
```

```
--seq-id-mode 0
-s 5.7
-e 1e-3
--max-seqs 10000
--threads 32
```

其中, 双向覆盖率要求查询序列与目标序列均达到 80%。最终, 300,000 条抽样链中有 92,277 条未检出满足上述条件的合格命中。其中，84,222 条至少包含一个具有 CATH 注释的结构域。

随后使用随机种子 20261106，从上述 84,222 条链中抽取 10,000 条，构建最终共同测试集。对于每条链，从具有 CATH 注释的结构域中随机指定一个作为真实答案 C，其余两个结构域按照链上的空间顺序作为输入 A 和 B。

需要注意的是，A、B 不要求具有 CATH 标签，真实答案 C 只要求具有可用的 CATH 注释，不要求完整的四级分类标签。最终测试集中，CATH 三级标签样本为 2,816 条，四级标签样本为 7,184 条。

四种方法及两种候选库设置均使用这 10,000 条相同查询，从而保证不同 Pipeline 之间的测试样本一致。

2.3 四种 Training-free 检索方法

本研究构建四种 Training-free 检索 Pipeline，主要从结构 Token 来源和查询融合方式两个方面进行比较。四种方法均使用相同的 DOMIN 编码器及其模型权重。

2.3.1 Native 3Di Embedding Addition

该方法使用输入结构域 A、B 对应的原始 3Di 结构 Token。首先分别通过 DOMIN Encoder 提取两个结构域的嵌入：

$$\mathbf{e}_A = f(A_{\text{3Di}}), \qquad \mathbf{e}_B = f(B_{\text{3Di}})$$

随后直接对两个嵌入进行加和，并进行 L2 归一化：

$$\mathbf{q}_{AB} = \text{Normalize}(\mathbf{e}_A + \mathbf{e}_B)$$

该方法采用简单的 Embedding Addition，不引入额外的生成式融合过程，用于评估原始结构 Token 对双域组合检索的支持能力。

2.3.2 Predicted 3Di Embedding Addition

该方法与上一方法采用相同的向量加和策略，但首先使用 ProstT5 分别预测 A、B 的 3Di 结构 Token。

随后通过相同的 DOMIN Encoder 提取嵌入：

$$\mathbf{e}_A = f(A_{\text{Predicted 3Di}})$$

$$\mathbf{e}_B = f(B_{\text{Predicted 3Di}})$$

最终查询表示为：

$$\mathbf{q}_{AB} = \text{Normalize}(\mathbf{e}_A + \mathbf{e}_B)$$

该方法与 Native 3Di Embedding Addition 的主要区别在于结构 Token 的来源，可用于分析预测结构表征与原始结构表征对检索性能的影响。

2.3.3 DOMO Fusion with Predicted 3Di

该方法采用 DOMO 对输入的两个结构域进行生成式融合，首先生成对应的完整蛋白质序列：

$$S_{AB} = \text{DOMO}(A, B)$$

随后使用 ProstT5 对生成序列预测 3Di 结构 Token，再将生成序列及其预测结构 Token 输入 DOMIN Encoder，获得最终查询表示：

$$\mathbf{q}_{AB} = f(S_{AB}, T_{AB}^{\text{Predicted 3Di}})$$

该方法通过 DOMO 生成完整序列，并利用预测结构信息构建融合后的查询表示。

2.3.4 DOMO Fusion with Sequence-only Input

该方法与 DOMO Fusion with Predicted 3Di 使用相同的 DOMO 生成序列，但不提供有效的结构 Token。

具体而言，将生成序列对应的结构 Token 全部设置为 `#`，再输入 DOMIN Encoder：

$$\mathbf{q}_{AB} = f(S_{AB}, \#)$$

其中，`#` 表示未知结构 Token。

需要特别说明的是，DOMO-Pred 与 DOMO-Seq 复用同一次 DOMO 序列生成结果，两者仅在后续结构 Token 输入上存在差异。因此，这一对照主要用于考察有效结构信息对生成式融合检索的影响。

2.4 Benchmark 构建与检索实现

本研究使用冻结的 10,000 条 AB→C 查询，分别构建两种候选库。

第一种为大规模候选库，使用已有的 FAISS IndexIVFFlat 索引，包含 40,782,345 个结构域候选，嵌入维度为 1,280，采用 Inner Product 进行相似度检索。检索设置为 $nprobe = 16$、$search_k = 256$。

第二种为闭合候选库，从 10,000 条测试链中分别提取 A、B、C 三个物理结构域实例，构成 30,000 个唯一候选域。其中，23,143 个候选域具有非缺失 CATH 标签。所有 10,000 个真实答案 C 均包含在该候选库中。

闭合候选库对全部候选域提取域级 3Di Token，并使用相同 DOMIN 权重进行编码。四种方法的查询向量则复用此前已经完成的编码结果，最终通过 FP32 内积计算完整的 10,000×30,000 相似度矩阵，执行 Exact Search。

两种候选库均采用一致的候选过滤原则：排除当前查询自身的 A、B 精确物理域实例，保留真实答案 C，并按照相似度排序跳过 CATH 标签为 - 的候选，最终选取前十个具有有效标签的候选域。

2.5 CATH 递进式宏平均评价指标

本研究采用 CATH 四级分类体系评价检索结果，包括 Class（C）、Architecture（A）、Topology（T）和 Homology（H）。

与各层级独立比较的方式不同，本次实验采用递进式匹配规则：只有前一级分类匹配成功，才继续判断下一级分类。例如，真实标签为 1.2.3.400，而预测标签为 2.2.3.400，由于 Class 不匹配，因此四个层级均不计为命中。

对于每个查询的真实 CATH 标签，按照完整标签字符串进行分组。首先计算每个真实标签组内部的命中率，再对所有有效标签组进行等权平均，得到宏平均命中率：

$$\mathrm{MacroAcc}_{l,r} = \frac{1}{|\mathcal{G}|} \sum_{g \in \mathcal{G}} \frac{1}{|g|} \sum_{i \in g} M_{i,l,r}$$

其中，l 表示 CATH 分类层级，r 表示检索排名，$\mathcal{G}$ 表示完整真实 CATH 标签分组集合，$M_{i,l,r}$ 表示第 i 个查询在对应层级和排名下的递进式命中指示变量。

本次实验共形成 1,340 个真实 CATH 标签组。残缺标签仍作为独立分组参与宏平均；对于缺少 H 注释的真实标签，其 H 层命中记为 0，但该组仍保留在 H 层宏平均分母中。

此外，Rank 1 至 Rank 10 分别独立评价，不采用累计 Hit@K 方式。

3 大规模候选库检索实验：40.78M IVF

3.1 实验设置

大规模候选库实验使用包含 40,782,345 个结构域的 FAISS IndexIVFFlat 索引，对共同测试集中的 10,000 条 AB 查询分别执行四种方法的检索。

四种 Pipeline 共用相同候选索引及检索参数，并按照前述规则排除当前查询自身的 A、B，跳过无 CATH 注释的候选，保留前十个有效结果。

本节主要关注 Rank-1 检索结果，用于比较不同查询表示方法在大规模候选空间中的表现。

3.2 四种方法的 Top-1 检索性能比较

图 2 展示了四种方法在 40.78M 候选库下的 Top-1 CATH 宏平均命中率。

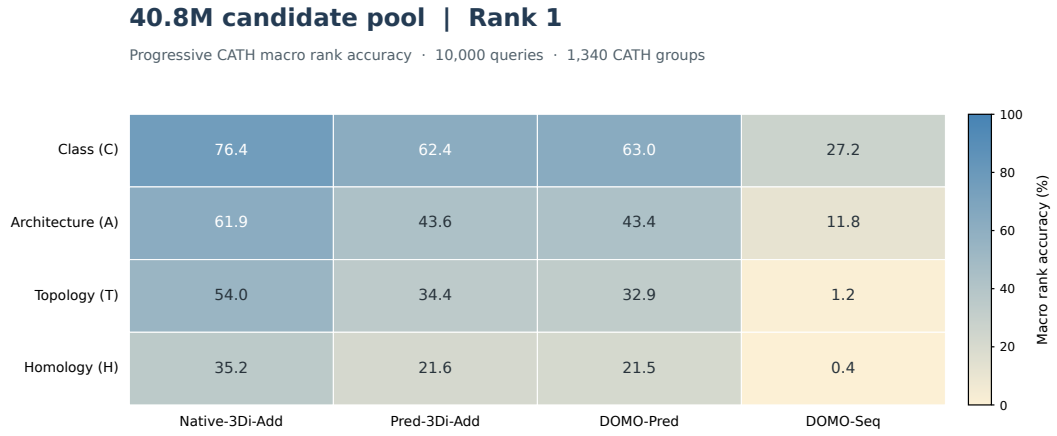


图 2: 40.78M Candidate Pool: Progressive CATH Macro Accuracy at Rank 1. 展示四种 Training-free 方法在约 4,078 万规模的 FAISS IVF 候选库中，Rank 1 检索结果在 CATH 四个分类层级下的宏平均命中率。

3.3 实验结果分析

从结果来看，Native-3Di-Add 在四个 CATH 分类层级均取得最佳表现，其 C、A、T、H 层命中率分别为 76.40%、61.90%、53.98% 和 35.25%。

Pred-3Di-Add 与 DOMO-Pred 的表现较为接近，H 层命中率分别为 21.63% 和 21.46%。相比之下，DOMO-Seq 的 H 层命中率仅为 0.38%，在更精细的 T、H 层级表现出明显劣势。

这一结果初步表明，原始结构 Token 的简单加和能够在大规模候选库中取得较强的检索性能。同时，仅依赖生成序列而缺少有效结构 Token，难以获得相近的精细结构域检索能力。

4 闭合候选库检索实验：30K Exact Search

4.1 闭合候选库构建与实验设置

为进一步考察固定测试域集合内部的检索表现，本研究构建了由 10,000 条测试链对应的 A、B、C 三个物理结构域实例组成的闭合候选库，共包含 30,000 个唯一候选域。

与大规模 IVF 实验不同，闭合候选库中的所有真实答案 C 均能够在候选集合中找到。因此，该实验主要用于分析在固定测试域集合及完整候选覆盖条件下，四种方法的相对检索性能与排名变化。

本实验采用完整 FP32 内积计算进行 Exact Search，并沿用相同的自身 A、B 排除和无标签候选过滤规则。

4.2 四种方法的 Rank 1–10 检索表现

图 3 展示了四种方法在 30K 闭合候选库中 Rank 1–10 的 CATH 宏平均命中率。

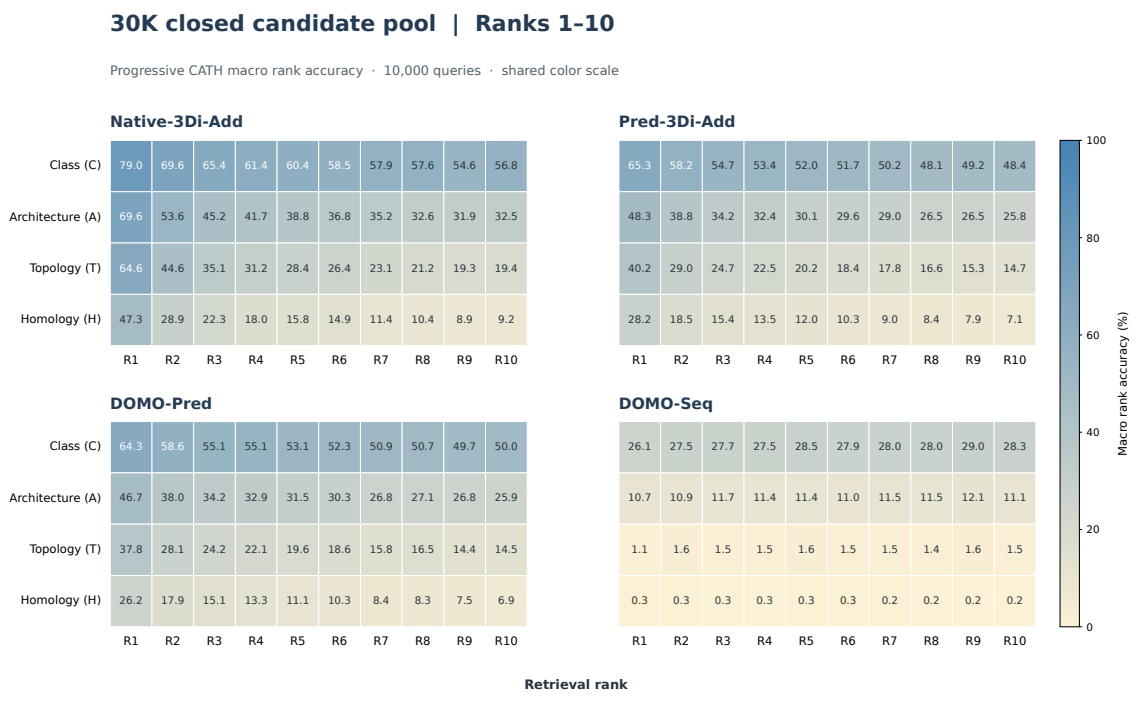


图 3: 30K Closed Candidate Pool: Progressive CATH Macro Accuracy across Ranks 1–10. 展示四种 Training-free 方法在 30,000 个闭合候选结构域库中，CATH 四个分类层级下 Rank 1–10 的宏平均命中率。

从整体结果来看，Native-3Di-Add 在四个 CATH 层级均取得最高的 Rank-1 命中率，并且在后续排名中整体保持领先。

Pred-3Di-Add 与 DOMO-Pred 的表现较为接近，两者均明显优于 DOMO-Seq。其中，DOMO-Seq 在 T、H 层级的命中率始终较低，说明缺少有效结构 Token 对精细分类层级的检索能力具

有明显影响。

4.3 H-level 检索排名分析

Homology（H）是 CATH 分类体系中最精细的分类层级。因此，进一步单独分析四种方法在 H 层级下随检索排名变化的表现。

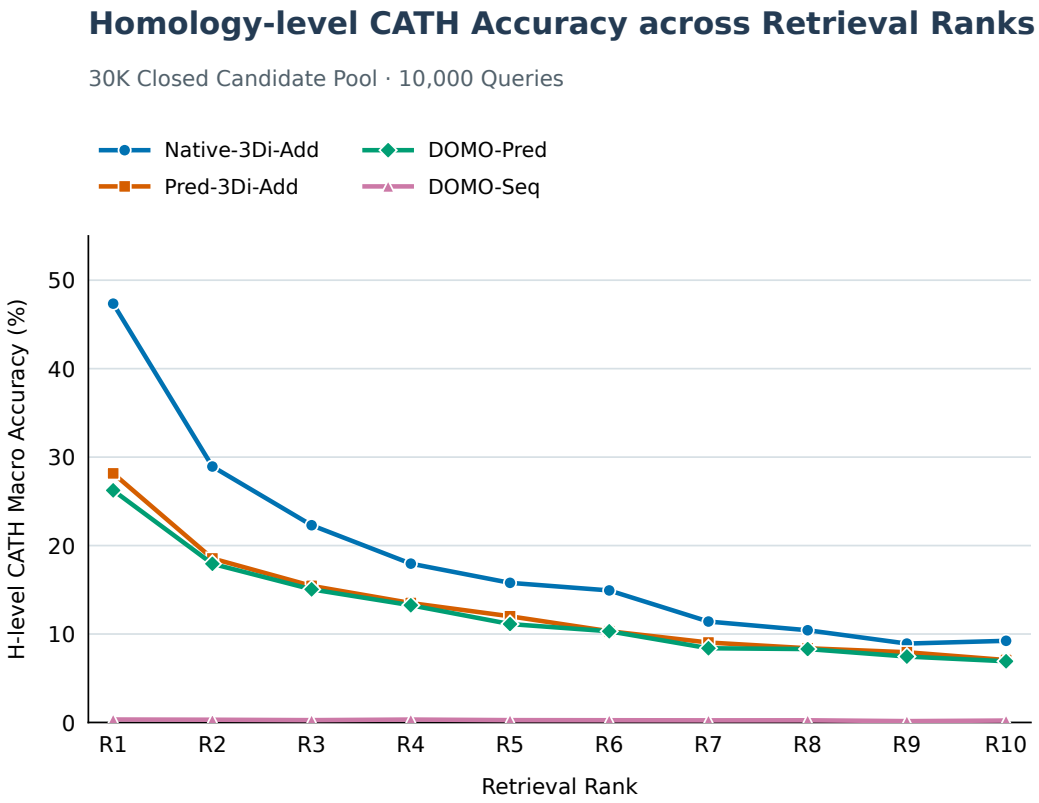


图 4: Homology-level CATH Macro Accuracy across Retrieval Ranks 1–10. 展示四种方法在 30,000 个闭合候选结构域库中，H 层级下 Rank 1–10 的宏平均命中率变化。

Native-3Di-Add 的 H 层命中率从 Rank 1 的 47.35% 下降至 Rank 10 的 9.23%，在整个排名区间保持领先。Pred-3Di-Add 与 DOMO-Pred 的 Rank-1 命中率分别为 28.16% 和 26.24%，Rank-10 则分别为 7.06% 和 6.92%。

DOMO-Seq 在 H 层级的命中率始终低于 0.4%，与另外三种方法存在明显差距。

值得注意的是，Native-3Di-Add 在 Rank 9 的命中率为 8.92%，在 Rank 10 小幅回升至 9.23%。这说明各排名位置采用独立评价时，命中率不一定严格单调下降。

4.4 两种候选库设置下的结果比较

表 1 汇总了两种候选库设置下四种方法的 Top-1 CATH 宏平均命中率。

表 1: 两种候选库设置下四种方法的 Top-1 CATH 宏平均命中率（%）。

方法	C	A	T	H
40.78M IVF				
Native-3Di-Add	76.40	61.90	53.98	35.25
Pred-3Di-Add	62.43	43.64	34.39	21.63
DOMO-Pred	63.01	43.41	32.92	21.46
DOMO-Seq	27.21	11.84	1.24	0.38
30K Exact				
Native-3Di-Add	78.98	69.62	64.56	47.35
Pred-3Di-Add	65.28	48.28	40.19	28.16
DOMO-Pred	64.26	46.74	37.76	26.24
DOMO-Seq	26.14	10.70	1.14	0.34

可以观察到，Native-3Di-Add 在两种候选库设置下均取得最佳 Top-1 表现，四种方法的相对性能排序基本保持一致。

其中，30K Exact 设置下前三种方法的绝对命中率整体高于 40.78M IVF，而 DOMO-Seq 的表现则较为接近。需要指出的是，两种实验不仅候选库规模不同，候选组成、真实答案 C 的覆盖情况及检索方式也存在差异。因此，不能将两种设置之间的数值差异简单归因于候选库规模或 Exact Search 本身。

5 总结与讨论

5.1 主要实验发现

本阶段完成了三结构域 AB→C 检索任务的共同测试集构建、四种 Training-free Pipeline 实现，以及两种候选库设置下的系统评价。

实验结果呈现出三个主要现象：

1. Native-3Di-Add 在 40.78M IVF 和 30K Exact 两种候选库设置下均取得最佳 Top-1 CATH 宏平均命中率。
2. Pred-3Di-Add 与 DOMO-Pred 的检索表现较为接近，复杂的生成式融合在当前任务中没有体现出明显优势。
3. DOMO-Seq 在 T、H 精细分类层级的表现显著下降，说明有效结构 Token 对精细结构域检索具有重要作用。

5.2 结构表征质量与融合策略的影响

Native-3Di-Add 与 Pred-3Di-Add 采用相同的 Embedding Addition 策略，但前者在两种候选库设置下均表现更好。这一对照说明，结构 Token 的来源及其表征质量可能是影响检索性能的重要因素。

另一方面，Pred-3Di-Add 与 DOMO-Pred 的表现接近，说明在当前实验条件下，引入 DOMO 生成式融合过程并未带来与其复杂程度相对应的检索收益。

此外，DOMO-Pred 与 DOMO-Seq 共享相同的生成序列，但后者不提供有效的结构 Token，检索性能明显下降。这一结果进一步支持结构信息对多结构域检索的重要性。

综合来看，当前实验更支持通过提高结构表征质量改善检索性能，而非单纯增加融合过程的复杂程度。

5.3 候选库构成与检索评价的影响

两种候选库实验在 Rank-1 相对性能排序上表现出较好的一致性，但在 Rank 1–10 的变化趋势上存在差异。

30K 闭合候选库包含全部真实答案 C，并采用完整候选集合上的 Exact Search；40.78M 实验则使用大规模 IVF 索引，其候选组成及真实答案覆盖情况与闭合库不同。

因此，两种设置提供的是互补的检索评价视角，不能将其差异简单解释为候选库规模带来的影响。后续若需要进一步区分候选组成与近似检索的贡献，可以在相同的 30K 候选集合和相同向量条件下增加 IVF 检索对照。

5.4 阶段性结论与后续工作

本阶段完成了三结构域数据分析与 Training-free Benchmark 的主要构建工作，形成了统一的 10,000 条 AB→C 查询、四种检索 Pipeline 和两种候选库评价设置。

目前结果表明，原始结构 3Di Token 配合简单的 Embedding Addition，在两种候选库设置下均具有最佳表现。这一发现强调了高质量结构表征在多结构域检索中的价值。

后续工作将主要围绕现有结果的整理、典型检索案例分析及实验可复现性检查展开，并在此基础上探索小参数模型训练与进一步的多结构域检索方法。